BoketeDBv5 のアノテーションの方法（最終版）とその根拠

1. 概要

BoketeDBv4 の全てのお題画像（6,823,270 枚．内容が同じ画像をまとめると 6,609,511 枚）に，形式・属性・媒体のラベルを付ける方法の最終版を決めた．ラベルの定義は定義書 v4（`programs/label_guideline/label_definition_v4.md`）である．

最終版の方法は次の 3 段からなる．

1. **生徒の確率**：2 つの生徒の確率を平均する．
   - SigLIP2-so400m の埋め込みに対する MLP（3 seed の平均）
   - 微調整した SigLIP2-B（224 画素）
   - 生徒は，Qwen3-VL-8B の教師ラベル（4 万枚と少ない区分の追加分，約 4.5 万枚）で学習した．
2. **お題文の確認**：お題文と予測した画像（約 8%）にだけ，Qwen3-VL-8B に確認の質問（O_v11_en）をする．
3. **整合の処理**：形式から属性を導き，媒体が空なら最も確率の高い媒体を付ける．

最終版の精度は次のとおりである．

評価	指標	値
通常の評価用データ（test，320 枚）	3 軸のマクロ F1 の平均	0.919
少ない区分の評価用データ（test）	ゲーム・絵画・カルタの F1 の平均	0.888
実データの目視ラベル 380 枚	全項目一致の割合（実際の分布での推定値）	0.838

ex008 の最良の生徒（埋め込みの MLP 単体）は，それぞれ 0.886，0.845，0.797 であった．処理時間は，単一の GPU で約 19 時間（予測約 12 時間，確認の質問 約 7 時間）と見積もった．

本稿では，最終版の方法（2 章）と，各要素を選んだ根拠（3 章）をまとめる．3 章の根拠は，report_001〜012 の結果と，本指示での比較による．

本指示での比較で，当初の案から変えた点が 2 つある．

- **確認の質問を O_v10_en から O_v11_en に替えた**．O_v10_en は，評価用データでは有効に見えた．しかし，全データから無作為に抽出した 2 万枚では，お題文ではないと答えた 145 枚のうち 98 枚（68%）が実際にはお題文であった．ボケてのテンプレートに書かれた「こんな〜は嫌だ」などの典型的なお題文である．典型的な型を明示した O_v11_en は誤って外さず，お題文ではないと答えた 9 枚はすべて正しかった．
- **ボケの書き出しによるカルタの取り消しを使わない**．生徒の予測では，評価用データ全体で 1 枚しか変わらず，その 1 枚は正しいカルタであった．

2. 最終版のアノテーションの方法

2.1 ラベルの定義

定義書 v4 の要点を表 1 に示す．

表 1 ラベルの定義（定義書 v4）．

軸	項目	定義の要点
形式（1 つ）	カルタ，穴埋め，お題文，通常	優先順に判定する．カルタはひらがな 1 文字の札の記号，穴埋めは語の代わりの空欄，お題文は投稿者が回答者に向けて書いた問い・指示・題目などの文
属性（複数）	空欄あり，カルタ記号あり，文字あり	文字ありは，ロゴや透かしを含め，読める文字があれば真
媒体（原則 1 つ）	写真，アニメ，ゲーム，マンガ，テキストグラフィック，絵画，イラスト	合成画像は，約 2 割以上を占める媒体を複数選ぶ．3DCG と生成 AI の画像は見た目で振り分ける

本指示で，お題文の定義に補足を加えた．ボケてのテンプレートや無地の背景に投稿者が書いた文が画像の主題である場合は，問いの形でなくてもお題文とする．台詞，題名，主張の文などである．回答者はその文を読んで大喜利を作るためである．ただし，ニュースの記事，ウェブやアプリの画面，テレビの字幕など，元からある文章を写したものは除く．

この補足に従い，既存の目視ラベルのうち 4 枚の形式を通常からお題文に改めた（`programs/ex009_final/format_relabel.txt`）．

2.2 処理の流れ

全データの処理は `programs/ex009_final/annotate_all.py` で行う．構成は `outputs/ex009_final/final_config.json` に記録した．表 2 に処理の流れを示す．各段階は途中の結果をファイルに保存するため，中断しても同じコマンドで再開できる．

表 2 アノテーションの処理の流れ．時間は単一の GPU（RTX PRO 6000 Blackwell）での見積もり．

段階	処理	対象	速度	時間
1. list	BoketeDBv4 の image の表から画像を列挙．sha256 が同じ画像は代表の 1 枚だけを予測する	6,823,270 枚 → 6,609,511 枚	—	数分
2. predict	画像を 1 回読み込み，so400m の埋め込み → MLP（3 seed），SigLIP2-B の微調整のモデルの確率を求めて平均する．埋め込みも保存する	6,609,511 枚	約 150 枚/秒	約 12 時間
3. verify	お題文と予測した画像に，Qwen3-VL-8B で確認の質問（O_v11_en）を行う	約 8%（約 54 万枚）	約 23 枚/秒	約 7 時間
4. finalize	確認の質問で偽なら，お題文以外で確率の最も高い形式にする．形式から属性を導き，お題ごとのラベルを保存する	6,823,270 件	—	数分

全データでの実行は次のとおりである．

```
.venv_annotate/bin/python programs/ex009_final/annotate_all.py --out_dir
↪ datasets/ex009_final/BoketeDBv5_annotation
```

出力の `annotation.parquet` は，1 行が 1 お題である．列は次のとおりである．

- お題 ID，sha256，予測に用いた代表のお題 ID
- 形式，属性 3 項目，媒体 7 項目
- 各項目の確率
- 確認の質問の記録（対象か，回答）

2.3 教師（学習用のラベルを作る Qwen3-VL-8B）

教師は，Qwen3-VL-8B-Instruct（vLLM，温度 0，JSON スキーマによる構造化出力，入力は最大 448×448 画素）への複数の質問の組み合わせである．最終版の教師 T_v10oJXk の構成を表 3 に示す．

表 3 教師 T_v10oJXk の構成．

軸	質問（部品）	用い方
形式	F_v2（形式と画風を問う短い英語のプロンプト）	形式の回答．text はお題文に読み替える
形式の確認	O_v10_en（投稿者が回答者に向けて書いた問いか）	F_v2 がお題文とした画像のみ．偽なら通常にする
属性	J_v6（3 軸を一括で問う日本語のプロンプト）	空欄あり，カルタ記号あり，文字あり（お題文あり OR その他の文字あり）
文字あり	X_v10_en（ロゴ等を含め，読める文字があるか）	「X_v10_en が真 かつ カルタ記号なし」を J_v6 の文字ありに論理和で加える
媒体	M_v6（媒体のみを問う日本語のプロンプト）	CG の回答は削除し，媒体が空ならイラスト
絵画	P_v8_en（美術作品の絵画か）	媒体の絵画を置き換え，絵画なら同時にイラストを偽にする

軸	質問（部品）	用い方
後処理	規則	ボケの書き出しによるカルタの照合，形式と属性の整合

教師ラベルは，次の画像に付けた．

- BoketeDBv4 から無作為に抽出した 4 万枚
- 少ない区分の追加分（5 回の収集，約 5 千枚）：Qwen がゲーム・絵画・カルタなどと判定する画像が各 1,000 枚以上になるまで，生徒の確率の高い画像を追加で収集したもの

教師の形式の確認に O_v10_en を用いた点は，最終版の確認の質問（O_v11_en）と異なる．O_v11_en で作り直した教師（T_v11）のラベルで学習した生徒は，全ての評価で劣った（3.6 節）．このため，教師は T_v10oJXk のままとした．

2.4 生徒

生徒は次の 2 つであり，確率を平均する．

- **埋め込みの MLP**：
  - 入力：SigLIP2-so400m（google/siglip2-so400m-patch14-384）の画像埋め込み（1,152 次元，float16，L2 正規化）
  - 構造：LayerNorm → 全結合（1,024 次元）→ GELU → Dropout 0.3 →形式・属性・媒体の 3 つの出力層
  - 学習：AdamW（学習率 3×10^{-4}，重み減衰 10^{-4} または 10^{-2}．教師ラベルの検証用分割で選択），40 エポック，検証用の 3 軸のマクロ F1 が最良のエポック
  - 3 つの seed の確率を平均する．
- **微調整した SigLIP2-B**：
  - モデル：google/siglip2-base-patch16-224 の画像エンコーダに，3 つの線形の出力層を付ける．
  - 学習：224×224 画素，色の揺らぎのみの拡張，AdamW（学習率 3×10^{-5}，重み減衰 0.05），バッチ 128，5 エポック，検証用で最良のエポック（seed 0）

損失は，形式の交差エントロピーと，属性・媒体の 2 値交差エントロピーの和である（重みなし）．

予測は次の規則で行う．

- 形式：確率が最大のもの
- 属性・媒体：確率 0.5 以上
- 媒体が空の場合：確率の最も高い媒体を付ける．
- 形式から属性を導く：カルタならカルタ記号あり，穴埋めなら空欄あり，お題文なら文字あり

2.5 お題文の確認の質問

O_v11_en の質問文（英語）の要旨は次のとおりである．

- 投稿者が回答者に向けて主題として書いた文があるかを問う．
- 真とするもの：
  - 問い（〜とは？），指示（〜してください）
  - 題目の句（こんな〜は嫌だ，〜あるある，〜した奴優勝，〜にありがちなこと）
  - 状況の設定，テンプレートや無地の背景に書かれた題名風の主題，名前の列挙
- 偽とするもの（文字が全て元の素材から来ている場合）：看板，ポスター，表紙，商品，テレビ・ニュースの画面と字幕，ウェブの記事，歌詞，図表，ゲーム・アニメ・漫画の台詞

3. 方法の根拠

3.1 VLM の教師から高速な生徒への蒸留（report_001，002）

方法	精度・速度	判断
Qwen3-VL-8B を全件に適用	精度は高いが，全件で約 70〜75 時間	定義を見直すたびに全件の再処理が必要
埋め込みのゼロショット分類	正解率 0.40〜0.50	不採用
メタデータを弱ラベルとした学習	正解率 約 0.70	不採用
Qwen の約 1 万〜4 万枚のラベルで生徒を学習（蒸留）	教師と同等以上の精度を，教師の 6 倍以上の速度で得る	**採用**

教師には Qwen3-VL-8B が最良であった．32B は同じ精度で約 3.3 倍遅かった．30B-A3B，InternVL3.5-8B，MiniCPM-V 4.5 は精度が劣った．

3.2 ラベルの定義（report_003〜012）

ボケの生成に必要な処理から逆算して，形式（排他）・属性（独立）・媒体の 3 軸とした．事前知識の軸と，媒体の CG，属性の合成画像は廃止した．判断がそろわず，下流での必要性も低いためである（report_007，010）．

文字ありは，読める文字があれば真とした（report_012）．文字が大喜利に影響しているかは画像だけでは判断できないため，ボケの文章を見る後段で判断する．

お題文からは，テロップや字幕など投稿者が重畳したのではない文を外した．これで教師のお題文の F1 は 0.63 から 0.79 に上がった（report_007）．

3.3 教師の構成（report_007，009，012）

- **質問の分け方：**形式・属性・媒体を 1 つのプロンプトで問うより，軸ごとに分けて問う方が良かった（report_006，007）．形式は短い英語のプロンプト F_v2 が最良であった．F_v2 の定義を書き換えた版（F_v8_en など）は，いずれも F_v2 を超えなかった（report_009）．
- **絵画：**独立の質問（P_v8_en）で，少ない区分の F1 が上がった（report_009）．
- **お題文：**
  - 説明を書き足す方法は失敗した．F_v2 に「元からある文字は除く」を書き足すと，お題文の誤検出がかえって増えた（実データで 13 件→ 18〜19 件）．
  - 別の短い質問で確かめる方法（O_v10_en）は，教師のお題文の F1 を実データで 0.769 から 0.873 に上げた（report_012）．
- **文字あり：**J_v6 の回答に，「X_v10_en かつカルタ記号なし」を加えた．実データでの文字ありの F1 は 0.954 から 0.971 に上がった（report_012）．

3.4 教師ラベルの集め方と損失（report_002，007，011，012）

- 教師ラベルの枚数を増やすと，精度は単調に上がった（1,000 枚で 0.841，3.6 万枚で 0.920．report_002）．
- 少ない区分の画像を追加で収集すると，少ない区分の F1 が上がった（report_007）．
- 重み付き損失は，定義書 v3 以降では効果がなかった．媒体を 2 つ以上付ける誤りが増えたため，廃止した（report_011，012）．

3.5 生徒のモデルの比較（本指示）

教師 T_v10oJXk の同じ教師ラベル（4 万枚と追加分）で，次のモデルとその組み合わせを比べた（図 1，表 4）．

- 埋め込みの MLP

- 微調整した SigLIP2-B（224 画素と 384 画素．384 画素は文字の細部を捉えるため）
- 確率の平均：MLP ＋微調整，3 seed の平均など

選択の指標は，通常の評価用データの dev の 3 軸の平均と，少ない区分の評価用データの dev の平均の平均とした．test と実データは確認のみに用いた．後処理は最終版（O_v11_en の確認）にそろえた．

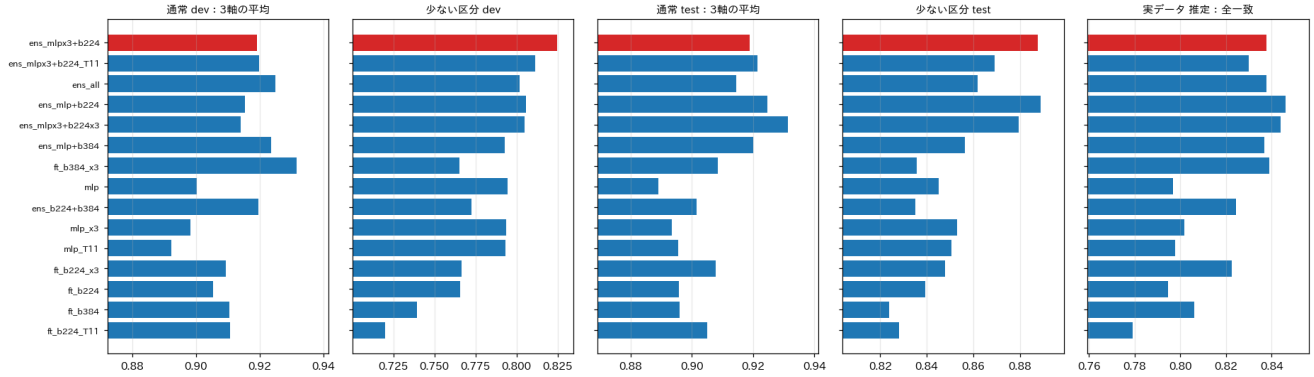


図 1　生徒のモデルの比較（後処理は最終版．赤が採用した構成）

表 4 生徒のモデルの比較．単体は 3 seed の平均．_x3 と mlpx3 は 3 seed の確率の平均（1 つの値）．全一致は実データの目視ラベルでの推定値．

モデル	選択の指標	dev 3 軸	少ない区分 dev	test 3 軸	少ない区分 test	全一致（推定）	予測の速度
MLP×3 seed ＋ SigLIP2-B 224（採用）	**0.872**	0.919	**0.825**	0.919	**0.888**	0.838	約 150 枚/秒
MLP ＋ SigLIP2-B 224 ＋ 384	0.863	0.925	0.802	0.914	0.862	0.838	約 115 枚/秒（推定）
MLP ＋ SigLIP2-B 224	0.860	0.915	0.806	0.925	0.889	**0.846**	約 150 枚/秒
MLP×3 ＋ SigLIP2-B 224×3	0.859	0.914	0.805	**0.931**	0.880	0.844	約 115 枚/秒（推定）
MLP ＋ SigLIP2-B 384	0.858	0.924	0.793	0.920	0.856	0.837	約 135 枚/秒（推定）
SigLIP2-B 384（×3 seed）	0.848	**0.932**	0.765	0.909	0.836	0.839	約 140 枚/秒（推定）
MLP（単体）	0.847	0.900	0.795	0.889	0.845	0.797	約 180 枚/秒
SigLIP2-B 224（単体）	0.836	0.905	0.766	0.896	0.839	0.795	約 750 枚/秒
SigLIP2-B 384（単体）	0.825	0.911	0.739	0.896	0.824	0.806	約 410 枚/秒

表 4 の「(推定)」は，各モデルの単体の速度から計算した値である．

- **確率の平均が最も効いた．**埋め込みの MLP と微調整した SigLIP2-B の確率を平均すると，単体のどちらよりも大きく良くなった．
  - 実データの全一致：約 0.80 → 約 0.84
  - 少ない区分の test：0.84 → 0.89
  - MLP は少ない区分に強く，微調整は通常の画像の形式・文字に強い．誤りの傾向が異なるためと考えられる．
- **384 画素の微調整は単体では dev が高い．**しかし，少ない区分の F1 が低く（dev 0.739），組み合わせでも 224 画素を上回らなかった．
- **3 seed の平均．**MLP は埋め込みを共有するため，3 seed にしても計算量はほとんど増えない．微調整のモデルを 3 seed にすると予測の時間が約 1.5 倍になるが，選択の指標は上がらなかった．
- **採用した構成．**選択の指標で最良の「MLP×3 seed ＋ SigLIP2-B 224」を採用した．「MLP ＋ SigLIP2-B 224」（seed ごとの平均）とは，実データと test でほぼ同等であり，差は seed による揺らぎの範囲内である．

3.6 後処理の比較（本指示）

採用したモデルに対し，次の後処理を比べた（図 2，表 5）．

- カルタの取り消し
- お題文の確認の質問（O_v10_en または O_v11_en）
- 通常と予測した画像のうち，お題文の確率がしきい値以上のものにも確認の質問をする方式

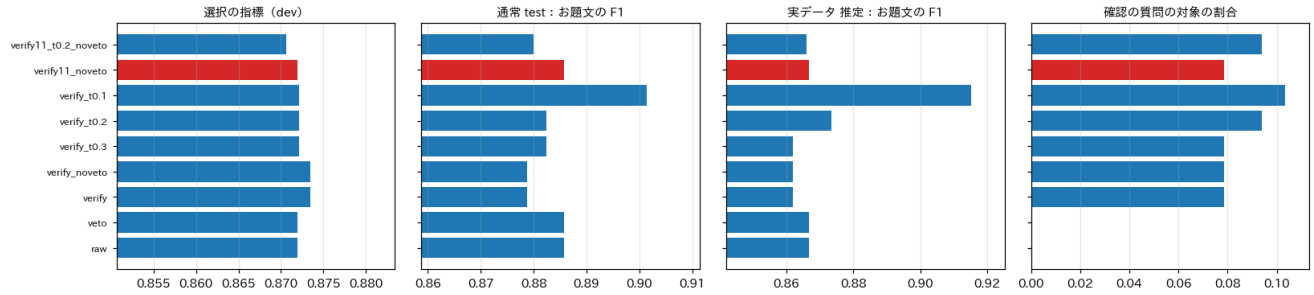


図 2　後処理の比較（採用したモデル．赤が採用した後処理）

表 5 後処理の比較（採用したモデル）．確認の対象は，実データで確認の質問の対象となる画像の割合の推定値．

後処理	選択の指標	test お題文 F1	全一致（推定）	お題文 F1（推定）	確認の対象
なし	0.872	0.886	0.838	0.867	0%
カルタの取り消し	0.872	0.886	0.838	0.867	0%
確認 O_v10_en	0.873	0.879	0.835	0.862	7.9%
確認 O_v11_en（採用）	0.872	0.886	0.838	0.867	7.9%
確認 O_v11_en（しきい値 0.2）	0.871	0.880	0.835	0.866	9.4%

評価用データ（640 枚，800 枚，380 枚）では，どの後処理もほとんど差がなかった．生徒の確率を平均したことで，お題文の誤検出が既に少ないためである．

一方，無作為の 2 万枚で全ての段階を動作させたところ，確認の質問の違いがはっきり表れた．お題文と予測した 1,615 枚のうち，O_v10_en は 145 枚をお題文ではないと答えた．これを目視で確認した（`programs/ex009_final/verify_reject_labels.txt`）．

表 6 確認の質問がお題文ではないと答えた画像の目視の形式（無作為の 2 万枚のうち，お題文と予測した 1,615 枚が対象）．

確認の質問	お題文ではないと答えた枚数	目視：通常	目視：穴埋め	目視：お題文（誤り）
O_v10_en	145	36	11	**98**
O_v11_en	9	9	0	**0**

O_v10_en が誤って外した 98 枚の多くは，ボケてのテンプレートに投稿者が書いた主題の文であった（図 3）．例えば，「こんな東方地霊殿は嫌だ」「こんな発声練習はダサい」「ここは俺にまかせろ！ お前は先にいけ！」である．評価用データにはこの種の画像が少ないため，評価用データだけでは O_v10_en の欠点が見えなかった．

O_v11_en は，お題文ではないと答えた 9 枚が全て正しかった．アプリのエラー画面，ゲームの画面，報道の画面，看板などである（図 4）．その効果は全データの約 0.05%（2 万枚中 9 枚）と小さいが，誤りは見つからなかった．このため O_v11_en を採用した．

あわせて，次の 2 つを確かめた．



図 3　O_v10_en が誤ってお題文から外した画像の例



図 4　O_v11_en でお題文から外した画像（無作為の 2 万枚のうちの 9 枚）

- **カルタの取り消し**：生徒の予測を 1 枚しか変えず，その 1 枚は正しいカルタであった（少ない区分の評価用データ）．教師では，カルタの F1 を 0.77 から 0.88 に上げた（report_006），生徒はカルタの誤検出が少ないため効果がない．使わないこととした．
- **教師を O_v11_en で作り直す案（T_v11）**：この教師のラベルで学習した生徒は，お題文と予測する割合が高くなり（実データで 9.5%），全ての評価で劣った（選択の指標 0.866，全一致の推定 0.830）．教師は T_v10oJXk のままとした．

3.7 最終版の精度

表 7 に，最終版の項目ごとの精度を示す．

表 7 最終版の項目ごとの F1．

項目	test（320 枚）	実データ 層別 220 枚	実データ 推定
カルタ	0.88	1.00	1.00
穴埋め	0.93	0.98	0.94
お題文	0.89	0.86	0.87
通常	0.96	0.97	0.97
空欄あり	0.94	0.98	0.95
文字あり	0.97	0.97	0.97
写真	0.97	0.96	0.98
アニメ	0.89	0.96	0.88
ゲーム	0.89（5 枚）	0.91	0.90
マンガ	0.91	0.98	0.99
テキストグラフィック	0.95	0.90	0.92
絵画	1.00（3 枚）	0.79	0.46
イラスト	0.78	0.73	0.82

少ない区分の評価用データ（test）の F1 は，ゲーム 0.857，絵画 0.837，カルタ 0.969 である．絵画の推定値（0.46）は，実データの目視ラベルに絵画が 15 枚しかなく，重みの大きい 1〜2 枚の誤りで大きく動くため不安定である．絵画の精度は，少ない区分の評価用データの値（0.84）で見るのが適切である．

図 5 に，無作為の 2 万枚のアノテーションの例を示す．無作為の 2 万枚でのラベルの割合は次のとおりである．

- 形式：カルタ 1.0%，穴埋め 19.9%，お題文 8.0%，通常 71.0%
- 文字あり：57.9%

3.8 処理時間と代替案

予測は，GPU での SigLIP2-so400m の計算が律速である．画像の読み込みのプロセス数を増やしても約 150 枚/秒であり，GPU のみの速度（約 205 枚/秒）に近い．前処理を torchvision に置き換えると，速度は変わらず，確率がわずかに変わった（最大 0.016）．このため，学習時と同じ前処理器を用いる．

処理時間を優先する場合の代替案を表 8 に示す．

表 8 処理時間を優先する場合の代替案．

構成	時間	精度（実データの全一致の推定）
最終版	約 19 時間	0.838
確認の質問を省く	約 12 時間	ほぼ同じ（全データの約 0.05% の誤りが残る）
SigLIP2-B 224 のみ	約 2.5 時間	0.795

いずれも `final_config.json` と `--stages` の指定で切り替えられる．

4. 注意点

1. **目視ラベル**：実データの目視ラベル（380 枚）と確認の質問の見直し（146 枚）は，Claude Code が 1 人で付けたものである．揺れが残るのは，次の境界である．

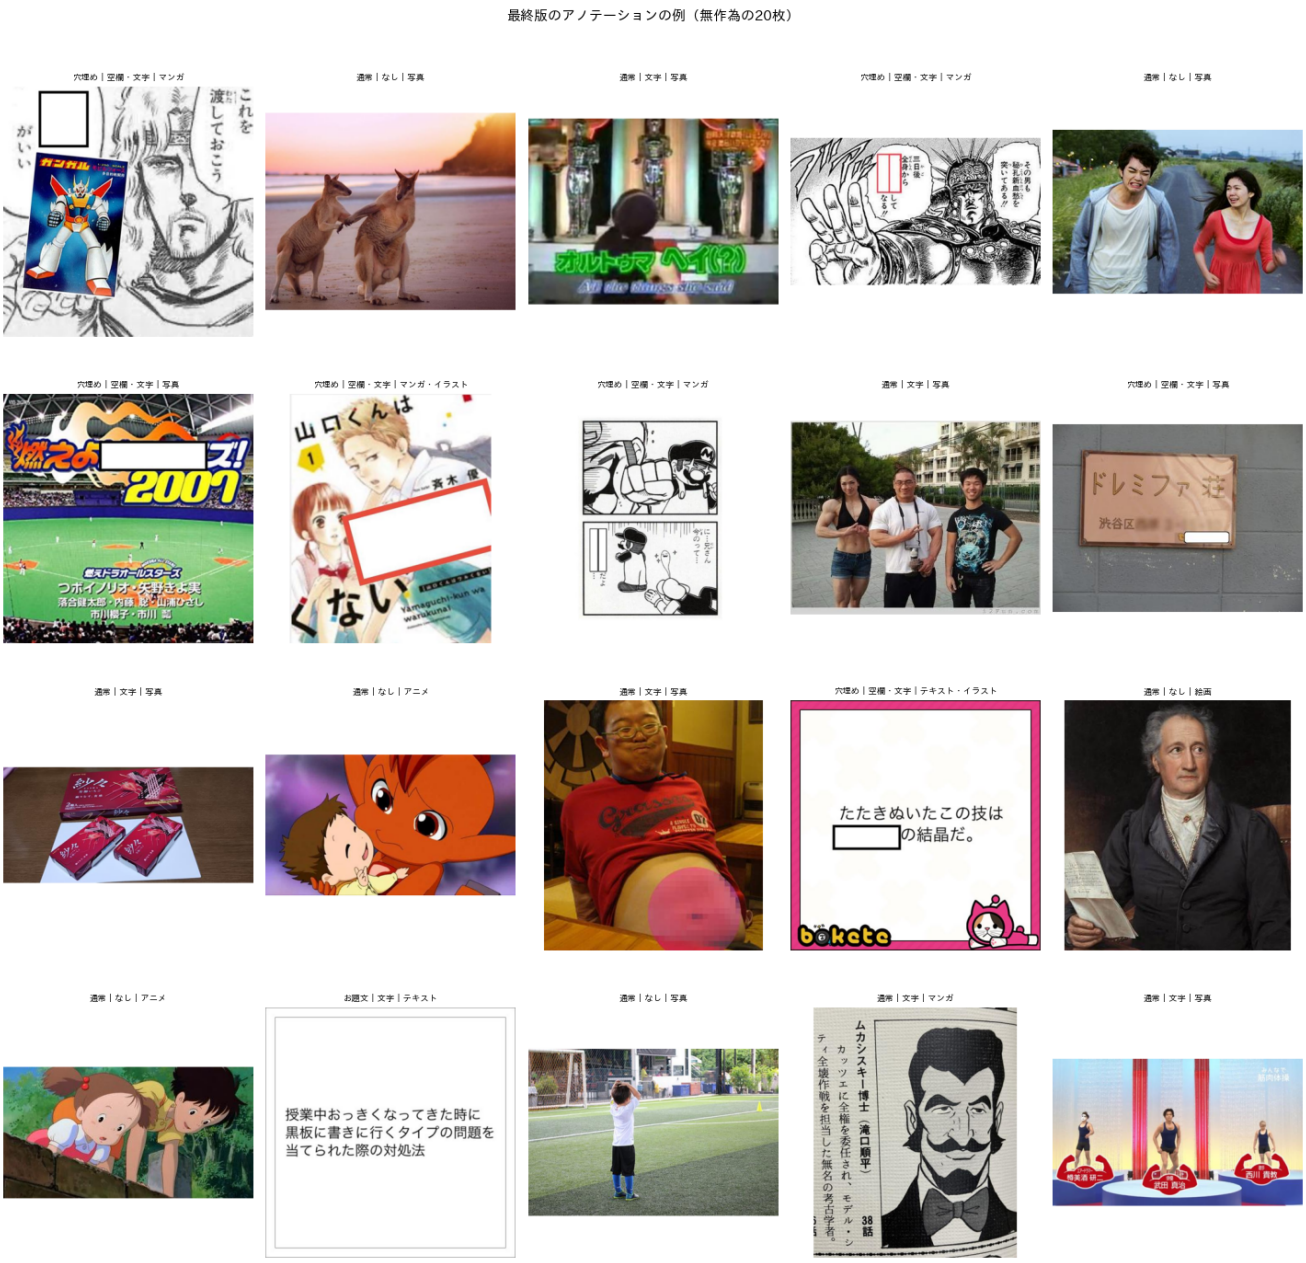


図 5　最終版のアノテーションの例（無作為の 20 枚．題は形式｜属性｜媒体）

- イラストとアニメ・ゲーム
- テンプレートの文をお題文とするか
- 約 2 割の領域に媒体を付けるか

2. **評価用データの偏り**：評価用データには，テンプレートに書かれた文の画像が少ない．後処理の判断（3.6 節）は，無作為の 2 万枚の目視に依った．全データでの実行後に，同様の無作為抽出で結果を確認するのが望ましい．
3. **教師ラベルの不整合**：教師ラベルの作成には O_v10_en を用いたため，テンプレートの文の一部が通常とされている．生徒はそれでもこれらの多くをお題文と予測した（無作為の 2 万枚で，O_v10_en が外した 98 枚は生徒がお題文と予測したもの）．影響は限定的である．
4. **埋め込みの保存**：全データの so400m の埋め込みは約 15GB で，`embeddings/` に保存される．定義を見直す場合は，教師ラベルを付け直して MLP を学習し直すだけで，埋め込みの再計算を省ける．