BoketeDBv5 のお題画像のアノテーションの実施

1. 概要

report_013 の最終版の方法を，独立したパッケージ `Bokete_Annotation_programs_v5.0/` として実装した．このパッケージで，BoketeDBv4 の全てのお題画像（6,823,270 件）にアノテーションした．

- **パッケージ**：研究用のプログラム（`programs/`）には依存しない．このディレクトリだけで，セットアップから実行，結果の確認までできる．README.md，前提データと出力の形式，ラベルの定義，方法と精度の説明，テストを含む．
- **研究用の版との一致**：無作為の 2 万枚で，研究用の版（ex009 の `annotate_all.py`）の結果と比べた．全てのラベル，確率，確認の質問の回答が一致した．
- **全データの結果**：
  - 保存先：`Bokete_Annotation_programs_v5.0/outputs/BoketeDBv5_annotation/`
  - 処理時間：予測 約 10.2 時間（180 枚/秒），確認の質問約 4.8 時間（32 枚/秒）
  - 確認の質問：55 万 1,260 枚に行い，3,998 枚をお題文から外した．
- **目視の確認**：ラベルごとに無作為の 20 枚を確認した．
  - カルタは 20 枚とも正しかった．
  - お題文は 20 枚中 19 枚が正しかった．

2. パッケージの構成

表 1 に，パッケージの構成を示す．

表 1 `Bokete_Annotation_programs_v5.0/` の構成．

パス	内容
`README.md`	概要，動作環境，セットアップの流れ，前提データ，実行方法，出力，注意
`docs/label_definition.md`	ラベルの定義（定義書 v4 と補足）．出力の列名との対応を付録に記す
`docs/data_format.md`	前提データ（BoketeDBv4 の `image` の表，お題画像）と出力の形式
`docs/method.md`	方法，生徒の学習，精度，処理時間
`annotate.py`	実行のエントリーポイント
`config.json`	構成（モデルの重み，確認の質問，読み込みのプロセス数）
`bokete_annotation/`	本体．`labels.py`，`data.py`，`models.py`，`verify.py`，`postprocess.py`，`pipeline.py`
`models/`	重み（4 ファイル，約 390MB）．Git の管理外とし，`README.md` に配布の方法を，`checksums.sha256` に SHA-256 を記録した
`scripts/check_models.py`	重みのチェックサムの確認
`scripts/quality_check.py`	ラベルごとに無作為の画像の一覧を作る（目視の確認用）
`tests/test_postprocess.py`	後処理のテスト（pytest，3 件とも成功）
`outputs/`	アノテーションの結果（Git の管理外）

GitHub への公開に向けて，次の点に配慮した．

- **重みと出力**：重み（最大 372MB）と出力は，GitHub のファイルの容量の制限を超える．このため `.gitignore` で管理から外した．重みは GitHub Releases などで配布し，チェックサムで確かめる手順を書いた．
- **環境に依存する情報**：パス，トークン，個人の情報は含めていない．データの場所はコマンドライン引数で指定する．
- **依存ライブラリ**：`requirements.txt` は，動作を確認した版で固定した．`uv pip compile` で依存関係を解決できることも確かめた．
- **親のリポジトリ**：親のリポジトリの `.gitignore` に，このディレクトリを加えた．

3. 研究用の版との一致の確認

ex009 の `annotate_all.py` と同じ無作為の 2 万枚（同じシード）で，両者の出力を比べた．

項目	結果
お題 ID の一覧	一致（2 万件）
形式，属性 3 項目，媒体 7 項目	全件一致
確率（14 列）	最大の差 0.0
確認の質問の対象と回答	全件一致（お題文から外したのは両者とも 9 枚）

全データの実行の途中で，画像の読み込みの方法を変えた（4 章）．変えた後の方法についても，次の 2 つを確かめた．

- 同じ 2 万枚で，確率が一致した（最大の差 0.0）．
- 保存の単位（シャード）の境界をまたぐ処理でも，確率と埋め込みが一致した．

全データの結果は，2 万枚の試行の結果と，同じ画像で全て一致した．

4. 全データの実行

全データの実行では，画像の読み込みのプロセスによるメモリ不足が 2 回起きた．このマシンでは，別のプロセス（VS Code のサーバー）が約 45GB のメモリを使っていた．次のように直した．

1. **1 回目**：読み込みのプロセスを fork で起動していたため，親のプロセスの大きな表が，書き込み時の複製でプロセスごとに増えた．
   - spawn で起動するように変えた．
   - spawn は起動に数分かかる．このため，全てのシャードで 1 つのデータローダーを用いる形にした．
2. **2 回目**：読み込みのプロセスが 24 個では，空きのメモリが 7GB まで減った．16 個に減らすと，空きは約 25GB で安定した．

この経過は README.md の動作環境（メモリ 64GB 以上．読み込みのプロセス数 16 で約 55GB）に反映した．中断した分は，保存済みのシャードから再開した．

表 2 に，全データの処理の記録を示す．

表 2 全データの処理の記録（RTX PRO 6000 Blackwell）．

段階	対象	速度	時間
list	6,823,270 件（内容が同じ画像をまとめて 6,609,511 枚）	—	数分
predict	6,609,511 枚	180 枚/秒	約 10.2 時間
verify	551,260 枚（8.3%）	32 枚/秒	約 4.8 時間
finalize	6,823,270 件	—	数分

確認の質問の速度は，2 万枚での見積もり（約 23 枚/秒）より速かった．一度に推論する枚数が多いためである．

出力の大きさは次のとおりである．

出力	大きさ
`annotation.parquet`	584MB
埋め込み	15GB
確率	328MB

5. 結果

5.1 ラベルの分布

表 3 に，全データのラベルの割合を示す．

表 3 全データ（6,823,270 件）のラベルの割合．

形式	件数	割合
カルタ	74,129	1.1%
穴埋め	1,369,160	20.1%
お題文	563,347	8.3%
通常	4,816,634	70.6%

属性・媒体	件数	割合
空欄あり	1,460,006	21.4%
カルタ記号あり	74,756	1.1%
文字あり	3,995,840	58.6%
写真	3,624,512	53.1%
アニメ	618,613	9.1%
ゲーム	158,890	2.3%
マンガ	1,039,983	15.2%
テキストグラフィック	988,116	14.5%
絵画	62,888	0.9%
イラスト	761,477	11.2%

その他の集計は次のとおりである．

- 媒体を 2 つ以上付けた画像：6.0%
- 確認の質問の対象：8.3%
- 確認の質問でお題文から外した画像：3,998 件（全体の 0.06%）

出力の整合も確かめた．

- 全てのお題に 1 行があり，欠損はない．
- 全ての画像に 1 つ以上の媒体がある．
- 埋め込みは，内容が同じ画像をまとめた 6,609,511 枚の全てにある．

5.2 目視の確認

`scripts/quality_check.py` で，各ラベルについて無作為に 20 枚を抽出した一覧を作り，目視で確かめた（図 1〜4）．

ラベル	20 枚中の正しい枚数	誤りの内容
カルタ	20	なし
お題文	19	「次回「　」」の空欄を含む画像を，穴埋めではなくお題文とした（1 枚）
ゲーム	約 18	ゲームの画面かどうか判断の難しい合成画像
絵画	約 17	古い雑誌の広告風のイラストを絵画とした

いずれも report_013 で報告した精度（お題文の F1 0.87，絵画は少ない区分の評価用データで 0.84）と整合する．

絵画の割合（0.9%）は，ex007 の生徒による推定（0.4%）より高い．一覧には，宗教画や肖像画などの正しい例に加えて，古いイラストも含まれる．絵画を厳密に使う場合は，確率の列 `p_painting` のしきい値を上げることを勧める．

6. 今後の課題

1. 重みと出力の配布の方法を決める．重みは GitHub Releases，出力は大容量の保存先を想定している．



図 1　お題文と判定した画像（無作為の 20 枚）

2. 公開前にライセンスと引用の方法を決める．README.md には，まだ記していない．
3.「文字あり」の画像について，ボケの文章を見て，文字が大喜利に影響しているかを判断する後段の処理を作る（定義書 v4）．

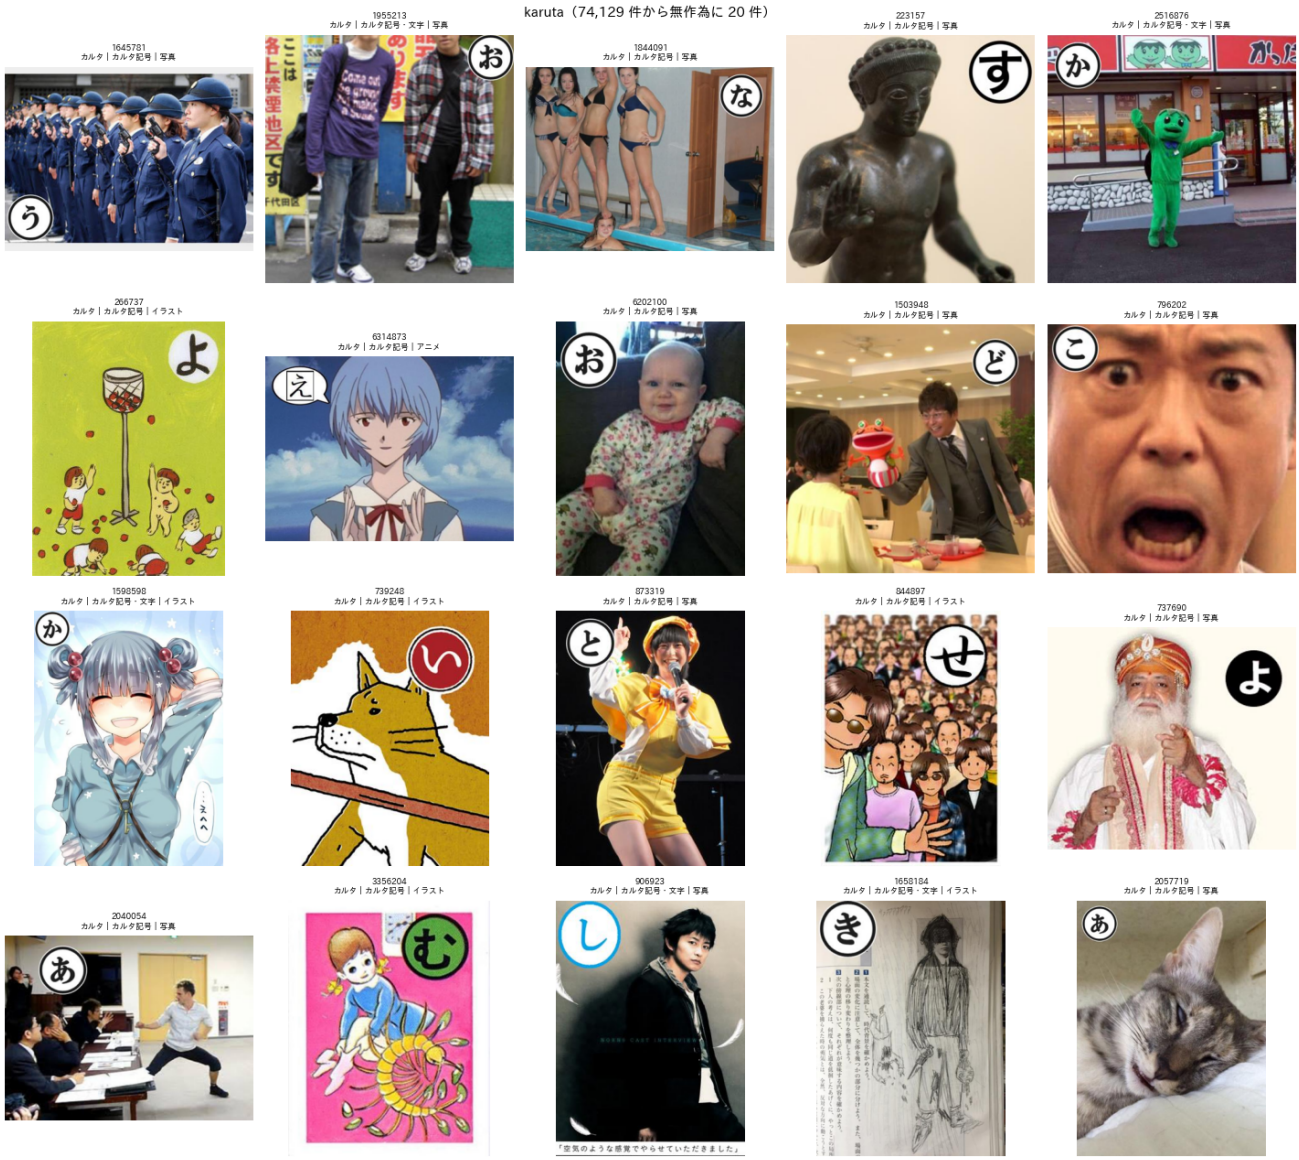


図 2　カルタと判定した画像（無作為の 20 枚）

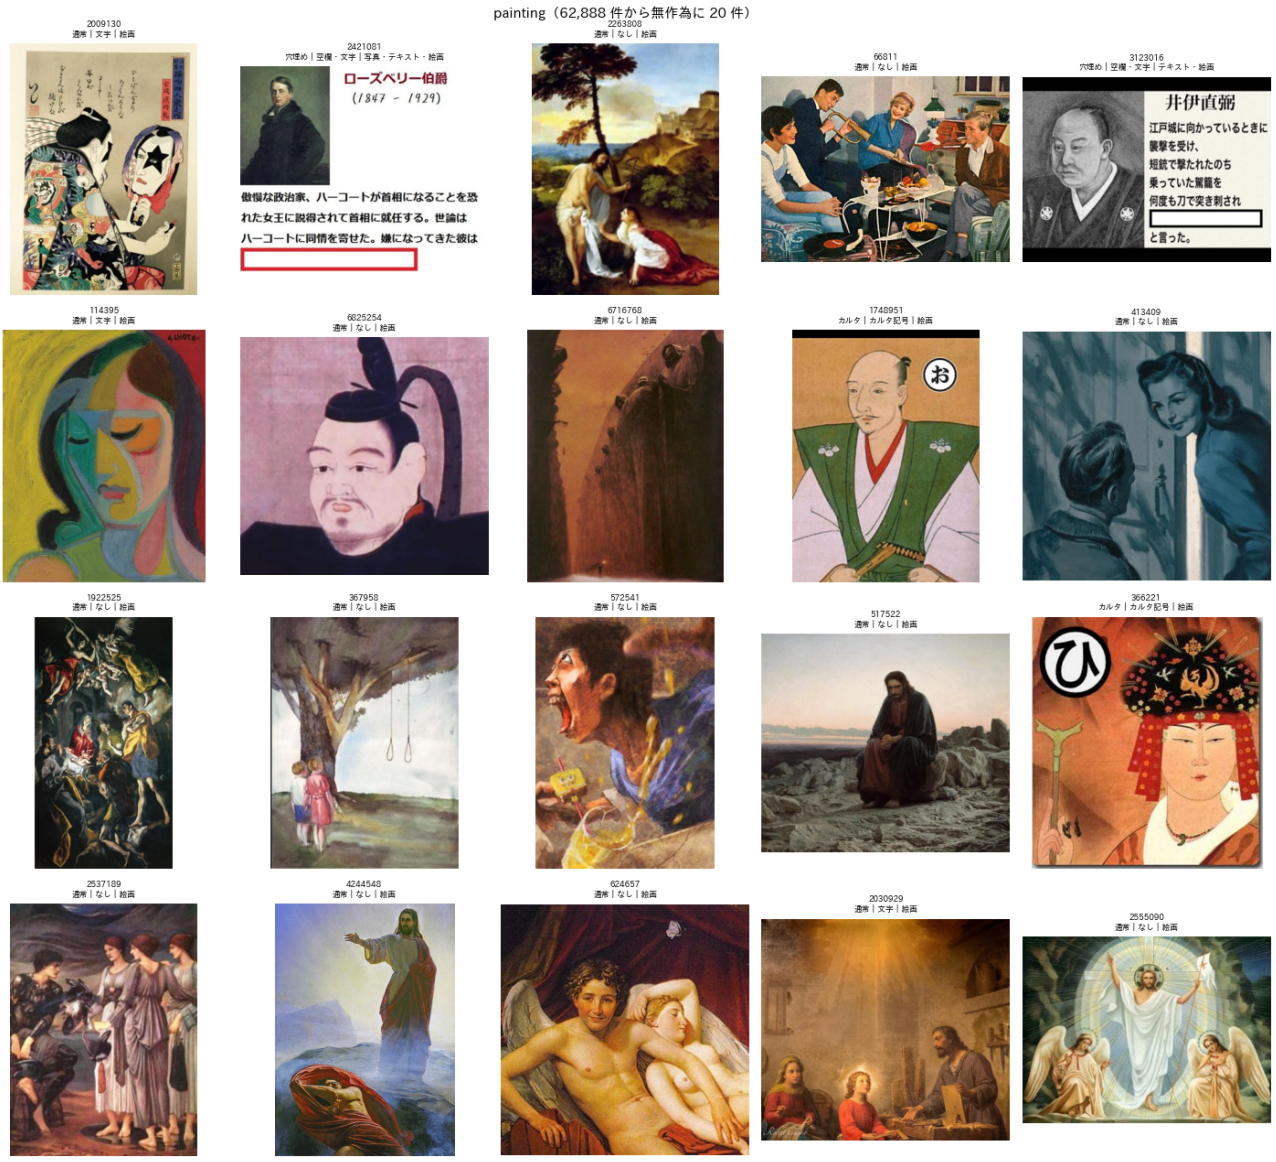


図 3　絵画を含むと判定した画像（無作為の 20 枚）

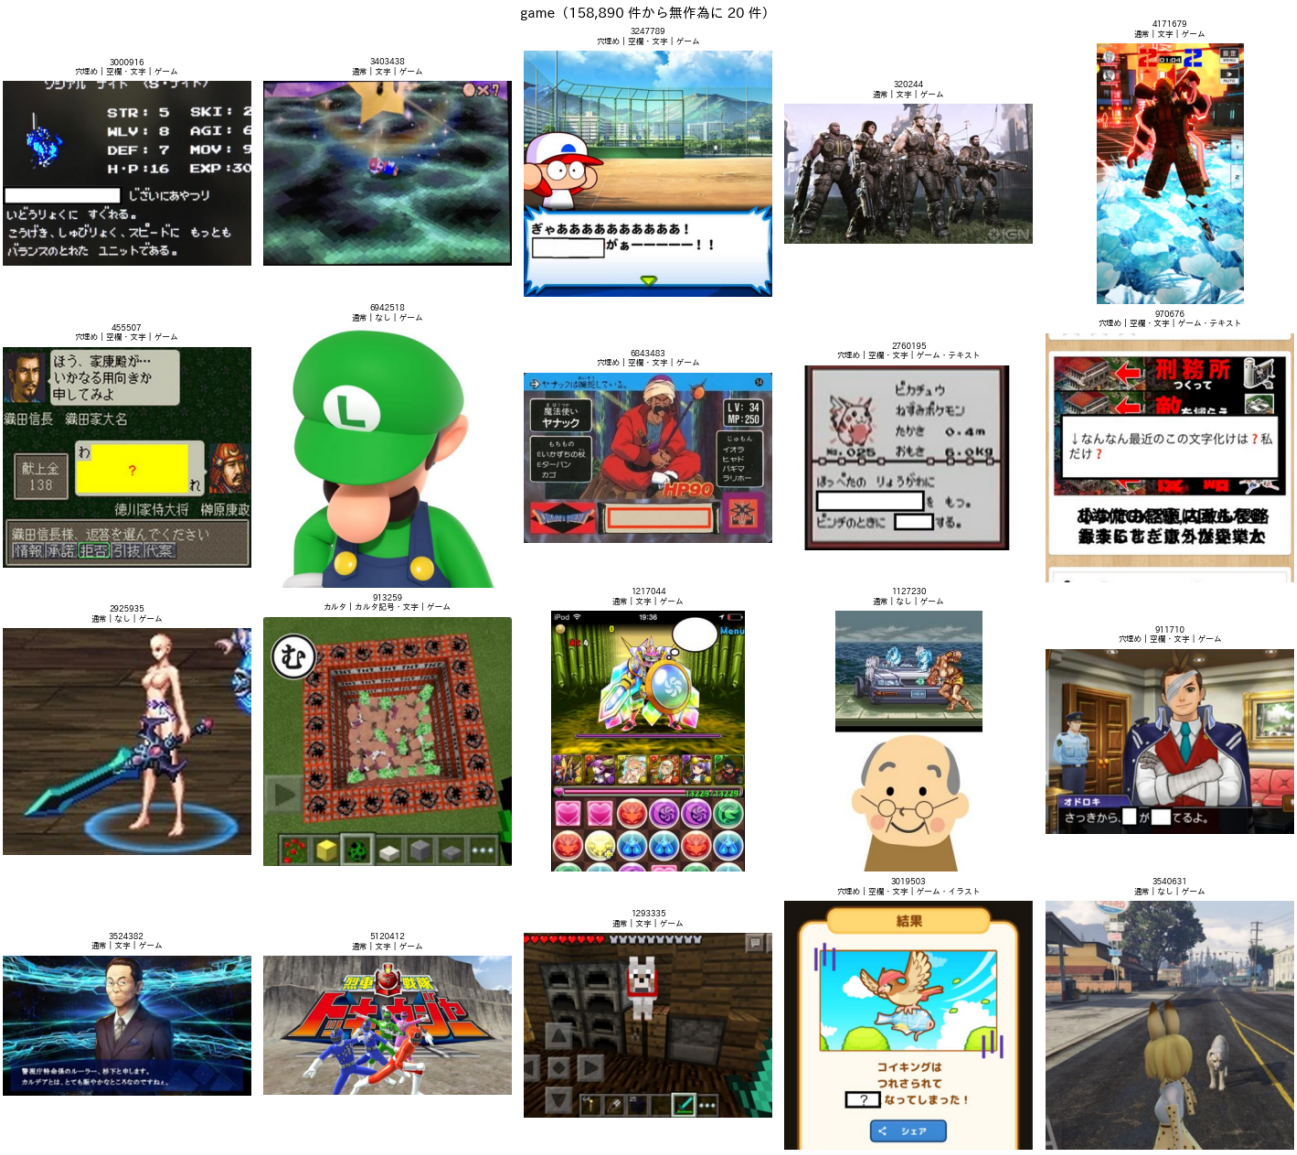


図 4　ゲームを含むと判定した画像（無作為の 20 枚）