写真のお題画像のキャプションの実施

1. 概要

report_016 の本番の設定で，写真のお題画像の全てにキャプションを付けた．設定は，Qwen3-VL-30B-A3B（FP8），448 画素，短い指示，温度 0，再現性の設定ありである．

項目	結果
対象	媒体が写真のみの画像 3,371,140 枚（内容が同じ画像は 1 枚と数える）．お題の数では 3,474,756 件
処理時間	約 19.1 時間（10/21 15:21 〜 10/22 09:41，平均 49.0 枚/秒）
出力	`outputs/ex011_caption_final/photo_captions/`
正常でない文	106 件（0.003%）．列 `caption_ok` で区別できる
目視の確認	無作為の 20 枚のうち，約 17 枚は概要として正しかった

`Bokete_Annotation_programs_v5.0/` は読み込みのみに用い，編集していない．

2. 出力

ファイル	内容
`captions.parquet`（137MB）	画像（代表のお題 ID）ごとの結果．列 `odaiId`，`caption`（句読点を「、」「。」にそろえた文），`caption_raw`（モデルの出力そのもの），`n_tokens`，`finish`
`photo_captions_by_odai.parquet`（77MB）	お題ごとの結果．列 `odaiId`，`rep_odaiId`，`caption`，`caption_ok`．内容が同じ画像のお題には同じ文が付く
`summary.json`	設定，出力の検査，処理速度
`postprocess.json`	正常でない文の件数と例

本番用のスクリプトは `programs/ex011_caption_final/caption_all.py`，品質の目印とお題ごとへの展開は `programs/ex011_caption_final/postprocess_captions.py` である．

3. 出力の検査

表 1 全 3,371,140 枚の検査．

項目	件数	割合
空の文	0	0%
最大トークン数での打ち切り	17	0.0005%
80 字を超える	11	0.0003%
改行を含む	2	0.0001%
日本語を含まない（英語の文）	75	0.002%
2 文以上	30,969	0.9%

項目	件数	割合
文字数	平均 25 字，95% 点 34 字	

2 万枚の試行（report_016）では，異常は 0 件であった．全件では，まれに次の 3 種類の壊れた出力が現れた．

- **同じ語の繰り返し**：例：「…男性の手を包丁で包丁で包丁で…」．最大トークン数で打ち切られる．
- **指示文の言い直し**：例：「アシスタントは、写真の内容を日本語で 30 字程度の 1 文で…」「はい、承知いたしました。…」
- **英語の文**：例：「spotted fawn lying on the ground, looking directly at the camera」

再現性の設定により，同じ画像では同じ壊れた文が再び出る．このため，付け直さずに `caption_ok` を偽とした（106 件）．判定の規則は次のとおりである．

- 打ち切り，80 字超，改行，日本語を含まない文
- 指示文の言い直しで始まる文
- 同じ語の 4 回以上の繰り返し．ただし，笑い声（「はっはっはっ」）や数字（「0.000…」）など，画像中の文字の引用は除く

これらを本当に必要とする場合は，指示文か乱数の種を変えて，106 枚だけを付け直せばよい．

英語の語句が日本語の文に混ざる例は，約 0.04%（1,421 件）あった．例：「bomber jacket を着た男性」．このうち約半数は，画像中の英語の文字の引用である（例：「「only god can judge」と書かれたステッカー」）．意味は通じるため，正常とした．

4. 目視の確認

図 1 に，お題ごとの結果から無作為に抽出した 20 枚を示す．

20 枚のうち，約 17 枚は概要として正しかった．誤りは次の 3 件である．

番号	キャプション	誤り
08	日本製の 100 枚入りのフクロタイプの栓材	実際はコーヒーのペーパーフィルターで，物の種類を誤った
09	サーベル toothed cat が木に登っている	英語が混ざった．実際はサーバル
12	女性がベンチに座っている	実際は手すりにもたれている

これは，評価用データでの精度と整合する．評価用データでは，平均点 4.13，4 点以上の割合 87%，誤りを含む割合 13% であった（report_016）．

5. 処理速度

全体の平均は 49.0 枚/秒であった．最初の 15 シャード（75 万枚）は，1 シャード（5 万枚）あたり約 720 秒（約 69 枚/秒）であった．10/21 18:30 以降の 52 シャードは，約 1,040 秒（約 48 枚/秒）に下がり，最後まで戻らなかった．

原因は特定できなかった．終了後の GPU は待機状態であり，その時点での他の処理の有無も記録していない．候補は，他のアプリケーションによる GPU の利用と，温度による動作周波数の低下である．出力の内容は，速度によらず同じである（再現性の設定のため）．

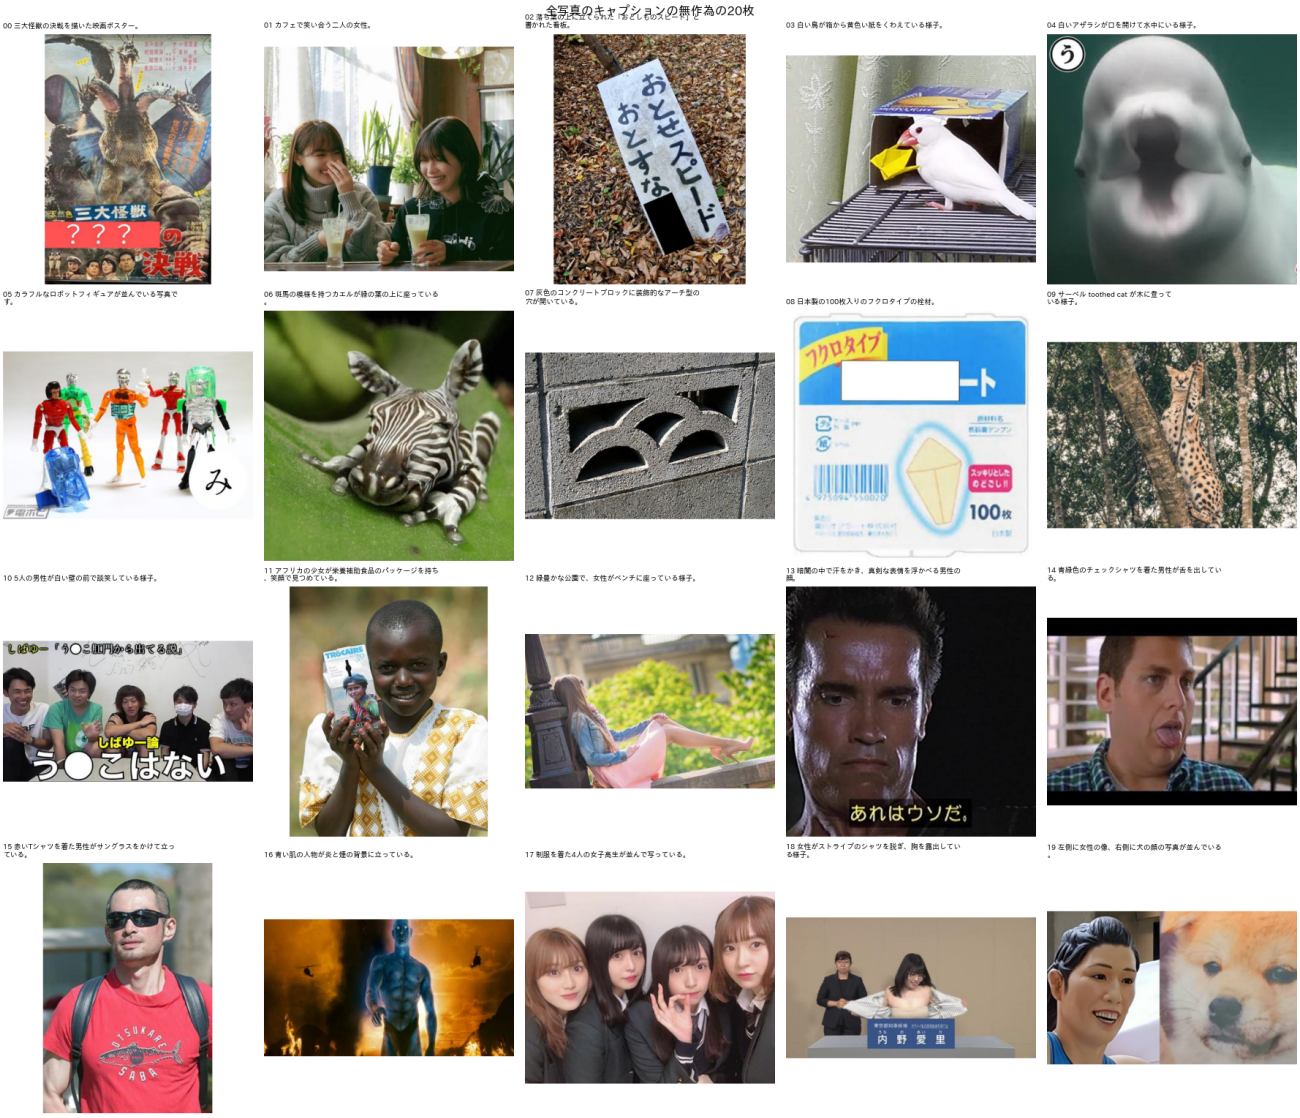


図 1　全写真のキャプションの無作為の 20 枚

今後，同じ規模の処理を行う場合は，次の 2 点を勧める．

- シャードごとの GPU の使用率と周波数を記録する．
- 実行中は，GPU を使う他のアプリケーションを止める．

6. 今後の課題

1. キャプションを BoketeDBv5 に加えるかを決める．加える場合は，`Bokete_Annotation_programs_v5.0/` のパッケージと出力の形式に入れる．
2. `caption_ok` が偽の 106 枚を付け直すかを決める．
3. 写真以外の媒体（アニメ，マンガ，イラストなど）のキャプションをどうするかを決める．