大喜利（ボケ）のラベル：小さな VLM による画像外の知識と発話の型の判定

1. 概要

画像外の知識の F1 と発話の型 6 区分のマクロ F1 を 0.8 以上にすることを目標に，お題画像とボケの両方を入力する小さな VLM を比べた．Qwen3-VL，InternVL3.5，LFM2-VL，SmolVLM2，Gemma 3 の 1〜4B と，推論（Thinking）モデルを試した．各モデルを，指示だけで判定させる方法（ゼロショット）と，微調整する方法で評価した．あわせて，検証データ 620 件の全件を元のラベルを見ずに付け直し，目視のラベル自体の再現性を測った．不一致を裁定した合意ラベルを正解とした．

結論は次のとおりである（最終評価用 312 件，合意ラベル）．

項目	前回（report_022）	今回の最良	目視のラベルの再現性
発話の型 6 区分（マクロ F1）	0.61（文の埋め込みの生徒）	**0.71**（InternVL3.5-2B ／ Qwen3-VL-4B の微調整）	0.80
画像外の知識（F1）	0.60（同上）	**0.69〜0.72**（Qwen3-VL-4B の微調整）	0.85
発話の型 3 区分（マクロ F1）	0.82	**0.85〜0.86**	0.93

- **目標の 0.8 には届かなかった．**
  - 6 区分は 0.61 から 0.71 に改善した．95% 信頼区間は 0.65〜0.77 である．
  - 画像外の知識は 0.60 から 0.69〜0.72 に改善した．
- **画像を入力する VLM の効果は，微調整して初めて現れた．**
  - 小さな VLM のゼロショットは，6 区分が 0.25〜0.44 にとどまった．画像外の知識は，多くのモデルが「はい」をほぼ出さない．
  - 推論モデル（32B，30B-A3B）も，前回の 32B 教師（Instruct）を上回らなかった．
- **最も効いたのは目視のラベルによる微調整である．**
  - 教師（32B）のラベルだけで学習した VLM は，教師と同程度だった（6 区分 0.55）．
  - そこから目視のラベル 931 件で微調整すると，0.70〜0.71 に上がった．
  - 教師のラベル自体が，目視のラベルとの一致で 6 区分 0.65，画像外の知識 0.63 にとどまり，これが上限を下げていた．
- **0.8 は，目視のラベルの再現性（6 区分 0.80，画像外の知識 0.85）とほぼ同じ高さである．**
  - 同じ定義でも，時間を置いて付け直すと 6 区分の約 2 割が変わる．したがって，0.8 は現在の定義では実質的に上限に近い．
  - 目視のラベルを 232 件から 931 件に増やした効果は 6 区分で +0.04 であり，増やすほど伸びは緩やかになる．
  - 0.8 に近づけるには，目視のラベルを数千件規模に増やすか，揺れの大きい区分（ツッコミ，心の声）の定義を見直す必要がある．

2. 目視のラベルの再現性と合意ラベル

2.1 方法

検証データ 620 件（report_022 の目視のラベル）を無作為に並べ替え，元の番号とラベルを伏せた一覧で，定義書第 3 版に従って付け直した．最初に 160 件を付け直し，次に残りの 460 件を付け直した．元のラベルとの一致を測り，不一致の項目を裁定して合意ラベルとした．

2.2 結果

表 1：元のラベルと付け直したラベルの一致（620 件）

項目	マクロ F1	一致率	Cohen の κ
発話の型 6 区分	0.80	0.86	0.82
発話の型 3 区分	0.93	—	—
画像外の知識	0.85（F1）	—	0.81

- 6 区分のクラスごとの F1 は，次のとおりである．
  - セリフ 0.89，回答 0.94，状況の説明 0.85，名付け 0.81．
  - 心の声 0.75，ツッコミ 0.55．
- 不一致の内訳は次のとおりである．
  - 多かったのは，心の声→セリフ（11 件），セリフ⇔ ツッコミ，状況の説明⇔ 名付けである．
  - 「形式が通常でも，お題画像が空欄や空の吹き出し，問いを課している場合」を回答とするかの揺れが，約 10 件あった．
- 合意ラベルの裁定では，次のように決めた．
  - お題画像が空欄・空の吹き出し・問いを課している場合は，形式によらず回答とする．この規則は定義書に追記する候補である．
  - 迷う場合はセリフとする（定義書のとおり）．
  - 画像外の知識の判断が分かれたものは，元のラベルを維持した．
- 合意ラベルは元のラベルから，発話の型 55 件，画像外の知識 22 件が変わった．以下の評価は全て合意ラベルを正解とする．

3. 比べた方法

方法	内容
ゼロショット	vLLM で，report_022 の指示 one_kt_cap（画像＋形式・媒体・キャプション＋ボケ）を与えて JSON を生成させる．画像は長辺 448 画素以下
推論モデル	Qwen3-VL-32B-Thinking-FP8，30B-A3B-Thinking-FP8．推論の後に JSON を書かせる（最大 4,096 トークン）
教師のラベルで微調整（stage 1）	VLM の言語モデルの最後のトークンの隠れ状態に，6 区分と画像外の知識の出力層を付け，LoRA（ランク 16，全線形層）で学習する．生成せず 1 回の順伝播で判定する．教師（32B one_kt_cap）のラベル 34,634 件を使い，4B は 2 エポック，2B 以下は 1 エポック学習した．4B では 1 エポック目が最良だった
＋目視のラベルで微調整（stage 2）	stage 1 の重みから，学習用の目視のラベル 931 件で 4 エポック微調整し，調整用で最良のエポックを選ぶ
目視のラベルのみ（対照）	VLM の初期値から，目視のラベル 931 件のみで 8 エポック学習する

学習用の目視のラベル（931 件）：- 抽出：教師のラベルの集合（検証データのお題を含まない）から，お題 1 件につき

1 件まで抽出した．- 半数は無作為に選んだ．- 残りは，教師のラベルで少ない型（心の声・ツッコミ・状況の説明・名付け）と，画像外の知識が「はい」のものを多めに選んだ．- 内訳：- 発話の型：セリフ 248，回答 206，状況の説明 156，名付け 152，心の声 109，ツッコミ 60．- 画像外の知識の「はい」：26%．- 教師のラベルとの一致：6 区分のマクロ F1 0.65（ツッコミ 0.33，状況の説明 0.51），画像外の知識の F1 0.63．教師のラベルには大きな誤りが含まれる．

モデル：- Qwen3-VL-2B/4B/8B，InternVL3.5-1B/2B/4B（HF 版），LFM2-VL-1.6B/3B，SmolVLM2-2.2B，Gemma 3 4B．- MiniCPM-V-4 と Heron-NVILA-Lite-2B は，vLLM の画像の処理でエラーとなり評価できなかった．- Gemma 3n と sarashina2-vision は，取得の権限がなく試せなかった．- 画像のトークン数は，タイル分割を止めて 200〜300 程度にそろえた．

速度：- ゼロショット：vLLM で 620 件を一括で生成したときの件数/秒．- 微調整：分類器の順伝播のみ（バッチ 32，bfloat16）の件数/秒．画像の読み込み・前処理を含む値は，その約 6 割である．

4. 結果

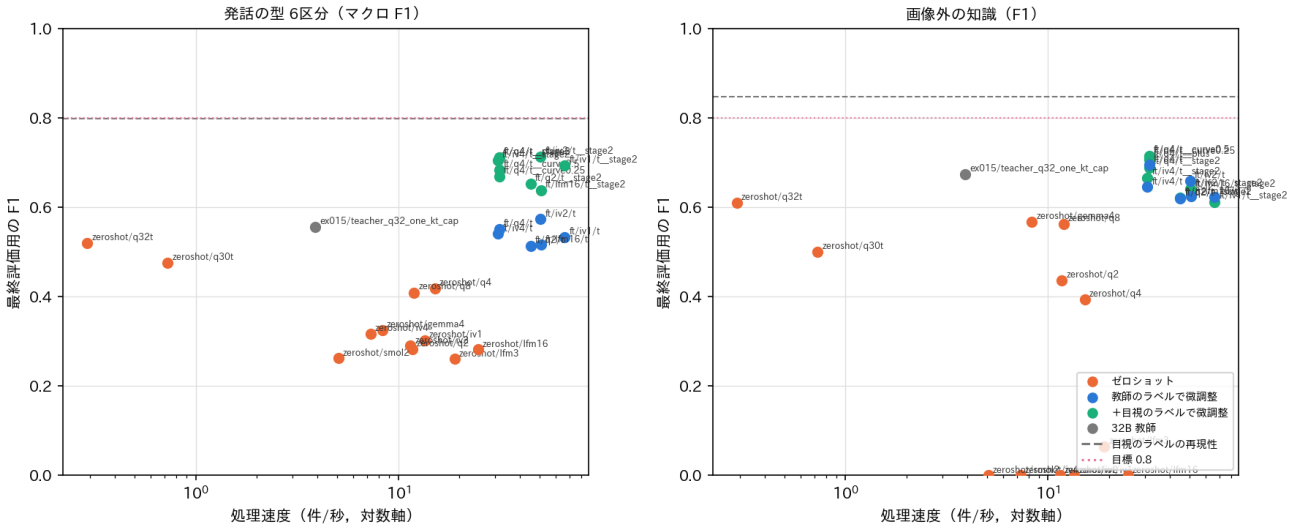


図 1　方法ごとの精度と速度（最終評価用）

表 2：主な方法の指標（合意ラベル．括弧内は調整用）

方法	6 区分 最終評価	3 区分 最終評価	画像外 最終評価	速度（件/秒）
前回：文の埋め込みの生徒（ex015）	0.611 (0.649)	0.824	0.599 (0.560)	未計測（文の埋め込みと MLP のみ）
前回：32B 教師 one_kt_cap	0.556 (0.559)	0.785	0.674 (0.561)	3.9
ゼロショット 32B-Thinking	0.520 (0.500)	0.789	0.610 (0.500)	0.3
ゼロショット Qwen3-VL-4B	0.418 (0.440)	0.744	0.394 (0.468)	15.2
ゼロショット Qwen3-VL-8B	0.409 (0.436)	0.713	0.563 (0.479)	11.9
ゼロショット 他の 1〜4B（7 モデル）	0.26〜0.33	0.54〜0.67	0.00〜0.57	5〜25
教師のラベルで微調整 Qwen3-VL-4B	0.552 (0.605)	0.790	0.695 (0.662)	31.6

方法	6 区分 最終評価	3 区分 最終評価	画像外 最終評価	速度（件/秒）
教師のラベルで微調整 InternVL3.5-2B	0.574 (0.579)	0.793	0.660 (0.608)	50.3
＋目視	**0.711** (0.758)	**0.864**	**0.690** (0.662)	31.6
Qwen3-VL-4B				
＋目視	**0.713** (0.768)	0.848	0.641 (0.623)	50.3
InternVL3.5-2B				
＋目視	0.705 (0.722)	0.853	0.667 (0.632)	31.0
InternVL3.5-4B				
＋目視	0.694 (0.705)	0.854	0.613 (0.610)	66.4
InternVL3.5-1B				
＋目視	0.652 (0.692)	0.836	0.621 (0.646)	45.0
Qwen3-VL-2B				
＋目視	0.639 (0.713)	0.850	0.639 (0.529)	50.7
LFM2-VL-1.6B				
目視のみ	0.673 (0.685)	0.844	0.548 (0.597)	31.6
Qwen3-VL-4B				
目視のみ	0.706 (0.695)	0.864	0.548 (0.565)	45.0
Qwen3-VL-2B				

ゼロショット：- 小さな VLM は指示だけではこの判定ができない．- 6 区分は，最良の Qwen3-VL-4B でも 0.42 だった．- InternVL3.5，LFM2-VL，SmolVLM2 は，画像外の知識をほぼ全て「いいえ」とした（F1 0）．- 推論モデルは 6 区分 0.52 で，Instruct の 32B 教師（0.56）を上回らなかった．- JSON を書き終えない割合が 23〜44% あった．- 速度は 32B 教師の 1/10 以下だった．

微調整：- 教師のラベルだけで学習した VLM は，画像外の知識で 32B 教師と同等以上（4B で 0.70）になった．6 区分は教師と同程度（0.55〜0.57）だった．教師のラベルを再現するところまでは学べるが，教師の誤りも再現する．- 目視のラベルでの微調整で，6 区分は全てのモデルで +0.12〜0.15 上がった．- 目視のラベルのみの対照は次のとおりである．- 6 区分は同程度（0.67〜0.71）である．- 画像外の知識は 0.55 で，教師のラベルで事前に学習した場合（0.69）より大きく低い．- 二段階の効果を分けると，次のようになる．- 画像外の知識は，教師のラベル（大量）から学んでいる．- 6 区分の境界は，目視のラベル（少量だが正確）から学んでいる．- クラスごとの F1（最終評価用，InternVL3.5-2B ／ Qwen3-VL-4B）は次のとおりである．- セリフ 0.83，回答 0.91，状況の説明 0.76〜0.78，名付け 0.74〜0.77．- 心の声 0.58〜0.64，ツッコミ 0.36〜0.45．- 目視のラベルの再現性でも低いツッコミと心の声が，マクロ F1 を下げている．- 次の工夫は効果がなかった．- Qwen3-VL-4B と InternVL3.5-4B の確率の平均．- 画像外の知識のしきい値の，調整用での選択．

表 3：目視のラベルの量と精度（Qwen3-VL-4B，教師のラベルで学習済みの重みから微調整．最終評価用）

目視のラベル	6 区分	画像外の知識
0 件（教師のラベルのみ）	0.552	0.695
232 件（25%）	0.669	0.713
465 件（50%）	0.684	0.716
931 件（100%）	0.711	0.690
931 件＋検証データの半分（約 310 件．2 分割で残り半分を予測）	0.712（調整用 0.755）	0.707（調整用 0.636）

- 6 区分は，目視のラベルを倍にするごとに +0.015〜0.03 程度伸びる．この傾向が続くとしても，0.8 には数千件以上が必要と見込まれる．ただし，これは観測した 3 点からの外挿であり，確かめていない．
- 画像外の知識は，目視のラベルを増やしても 0.69〜0.72 で変わらない．

5. 目標に届かなかった理由と考察

1. **目視のラベルの揺れ：**
   - 同じ定義での付け直しの一致は，6 区分で 0.80，画像外の知識で 0.85 だった．
   - 合意ラベルでも同程度の揺れが残ると考えられ，0.8 はモデルにとって上限に近い．
   - 特にツッコミ（再現性 0.55）と心の声（0.75）は，人でも安定しない．
2. **教師のラベルの誤り：**32B 教師のラベルは，目視のラベルとの一致で 6 区分 0.65，画像外の知識 0.63 にとどまる．教師のラベルだけで学習すると，教師の水準を超えない．
3. **画像外の知識の難しさ：**「特定の事物を知らないと分からない」の判断には，画像から事物を同定することと，世界知識を持つことの両方が要る．2〜4B の VLM は知識が少なく，目視のラベルを増やしても伸びなかった．誤りの多くは，有名な台詞・歌詞・ネットの定型を引用していることに気づかないものと，固有名詞が出てくるだけで「はい」とするものである．

6. 推奨する構成と，9,250 万件への適用

推奨する構成：InternVL3.5-2B または Qwen3-VL-4B を，教師のラベル（1 エポック）→目視のラベル（4 エポック）の順で微調整する．- InternVL3.5-2B：6 区分 0.71，3 区分 0.85，画像外の知識 0.64．分類器の順伝播で 50 件/秒．- Qwen3-VL-4B：6 区分 0.71，3 区分 0.86，画像外の知識 0.69．32 件/秒．

処理時間の見積もり：- 9,250 万件を前処理込みの速度（順伝播の約 6 割）で処理すると，InternVL3.5-2B で約 35 日，Qwen3-VL-4B で約 55 日かかる．- 現状のままでは全件への適用は現実的でない．- 同じお題画像に平均約 14 件のボケが付くため，画像の符号化をお題ごとに 1 回にすれば，大幅に短縮できる見込みがある．画像のトークンの計算を省けるためだが，まだ実装も計測もしていない．- 前回の文の埋め込みの生徒は，画像を処理しないため VLM よりはるかに軽い（速度は未計測）．用途に応じて，次のように使い分ける案がある．- 3 区分や，確率による絞り込みで足りる集計には，文の埋め込みの生徒を使う．- 画像外の知識など精度が要る部分集合には，VLM を使う．

7. 今後の進め方

1. **定義の見直し：**
   - お題画像が空欄・空の吹き出し・問いを課している場合の回答の扱いを，定義書に明記する．
   - ツッコミ（画像の人物への呼びかけを含む）と心の声の境界を見直す．
   - 6 区分の再現性を上げることが，自動判定の精度の上限を上げる前提である．
2. **目視のラベルの追加：**6 区分は目視のラベルの量で伸びている．2,000〜3,000 件に増やした学習曲線で，0.8 に届くかを確かめる．
3. **画像外の知識：**
   - 32B 以上の教師を，引用・パロディの元ネタを書き出させる指示で改善し，教師のラベルの質を上げる．
   - より大きな VLM（8B）の微調整も候補である．
4. **全件への適用の高速化：**お題ごとの画像の符号化の共有と，バッチの大型化を実装し，処理時間を計測する．

付録：実験の構成

- コード：programs/ex016_boke_small_vlm/

  - data.py：検証データ・合意ラベル・学習データ・目視のラベル
  - ceiling_sheets.py，human_sheets.py：付け直し・学習用の一覧
  - zeroshot.py：ゼロショットと推論モデル
  - model.py，train.py：分類器と微調整
  - stage2_more.py：目視のラベルの量の実験
  - evaluate.py，figures.py
  - run_queue.sh，run_queue2.sh：GPU の実行の順序
- ラベル（programs/ex016_boke_small_vlm/）：
  - ceiling_labels.txt，rest_labels.txt：620 件の付け直し
  - consensus160_labels.txt，consensus_labels.txt：合意ラベル
  - human_labels.txt：学習用 931 件
- 出力（outputs/ex016_boke_small_vlm/）：
  - zeroshot/{モデル}/{eval.csv,speed.json}
  - ft/{モデル}/{条件}[___stage2|___curve*|___plus]/0/{eval.csv,log.json,speed.json,best_model.pt}
  - figures/{summary.csv,table_methods.csv,fig_accuracy_speed.png}
- 追加したライブラリ：peft 0.21.2，num2words 0.5.14（requirements_annotate.txt）.
- 本検証は試作であり，Bokete_Annotation_programs_v5.0/ には含めていない.