共通の問題（30 問）の全員への出題

1. 概要

BoketeImageAnnotator に，全ての評価者に同じ問題を同じ順で最初に出題する共通の問題を 30 問設けた．共通の問題に回答し終えた後は，従来通り回答数の少ない問題から出題する．共通の問題により，評価者の甘さ・厳しさの個人差（report_032 の s）と評価者間の一致度を推定でき，問題ごとに多数決の正解を得られる．一方，全員が同じ問題のみに回答するとアノテーター × 軸のセルあたりの問題の数が少なく，一致率の推定は問題の抽出のばらつきで頭打ちになるため，残りの回答は従来通り問題に分散させる．

項目	内容
選択	`prepare/select_common.py`（新規. `data/common.sql`，`data/common_tasks.csv`）
出題	`src/tasks.ts`（`pickCommonTask`），`src/handler.ts`（`nextTask`），`schema.sql` と `migrations/002_add_common_tasks.sql`（`common_tasks` 表）
運用	起動のスクリプトが表を作り行を投入する．`npm run image:stats` に共通の問題の回答数を表示する．`npm run image:common:remote`
集計	`export_results.py`（`common_by_task.csv`，`common_by_rater.csv`，`summary.json` の Krippendorff の α と甘さの標準偏差）
確認	vitest 14 件，pytest 9 件，型の検査，模擬試験（全項目合格．共通の問題が 2 人の評価者に同じ順で最初に出ることを追加），集計と進み具合の表示の試験
コミット	`6f10531`

2. 共通の問題の選び方

アノテーター間の差は値が割れている問題でのみ生じる（report_032）．そこで，同じ画像・軸に 2 つの値（2 者が共有する値と 1 者のみの値）がある画像を軸ごとに 5 枚選び，各画像の 2 つの値をともに問題とした．1 者のみの値を付けたアノテーターは軸をまたいで Claude Code，Qwen，生徒モデルが 5 枚ずつとなるよう巡回させた．これにより，各アノテーターの値は 30 問中 15 問（1 者のみの値 5 問，2 者が共有する値 10 問）に現れる．同じ画像の 2 つの値を同じ評価者が判定するため，2 つの値をともに「一致する」とする矛盾（report_032 の媒体の例）も検出できる．説明の実例と注意確認の問題に使う画像は除き，同じ画像の 2 問が続かない無作為の順（乱数の種 0）に並べた．

軸	画像	問題	1 者のみの値のアノテーター（Claude Code / Qwen / 生徒モデル）
形式	5	10	2 / 2 / 1
画像の要素	5	10	2 / 1 / 2
媒体	5	10	1 / 2 / 2

3. 出題と運用

nextTask は，注意確認の問題を出す時でなければ，まず評価者が未回答の共通の問題のうち順（ord）が最も早いものを出し，全て回答済みなら従来の回答数の少ない問題を出す．注意確認の問題は従来通り 6〜12 問ごとに挟むため，共通の問題の間にも入る．共通の問題は既存の tasks 表を変えずに別の表 common_tasks に持つため，運用中のローカルの D1 の問題と回答はそのまま使える．起動のスクリプトは起動時に表を作り（何度実行してもよい），表が空なら data/common.sql を投入して「共通の問題：30 問」と表示する．既に問題に回答した評価者も，未回答の共通の問題から出題される．

4. 集計

export_results.py は data/common_tasks.csv があれば，共通の問題の回答から問題ごとの判定の分布，評価者ごとの「一致する」の割合と甘さ（問題ごとの「一致する」の割合との差の平均），軸ごとと全体の評価者間の一致度を求める．評価者間の一致度は「判定できない」を除いた名義尺度の Krippendorff の α とした．模擬の 3 人の回答（90 件）で集計とファイルの出力を確かめた．

5. 未解決の論点と次の作業の候補

- 動作中の npm run image:tunnel を再起動するまで共通の問題は出題されない．再起動時の表示「共通の問題：30 問」を確かめる必要がある．
- 共通の問題は全て値が割れた問題であり，全てのアノテーターが同じ値の問題を含まない．甘さの推定は難しい問題の上での値となり，個人差 s の推定には plan_sample_size.py の模型に合わせた混合効果のロジスティック回帰が必要である（未実装）．
- 1 人の回答が 30 問未満で終わると共通の問題の後半の回答が少なくなる．対面の評価では全員が 30 問以上に回答するよう時間を確保する必要がある．
- 開発者の動作確認の回答も共通の問題に入る．確認の後に「参加をやめる」で削除する必要がある．