お題文ありの属性の判定の改善

1. 概要

お題画像のラベルを，属性（カルタ記号あり，空欄あり，お題文あり，文字あり）と媒体の 2 軸にし，形式を属性から導く構成に改める．その準備として，「お題文あり」の判定の精度の改善に取り組んだ．「お題文あり」は，空欄やカルタ記号の有無と独立に付ける属性である．

結論は次のとおりである．

項目	結果
正解	定義書 v4 の目視のラベル 1,020 枚に，お題文ありを加えた．穴埋め・カルタの画像 328 枚は目視で付け直した．そのうちお題文ありは 30 枚（9%）であった
Qwen の指示の改善	現在の確認の質問（P0）を全画像に問うと，F1 は最終評価用 0.43，実データ 0.39（8B）であった．定義と判断の手順を明示した指示（P3）を 32B に高解像度で与えると，0.76，0.75 になった
モデルの比較	8B と 30B-A3B は，どの指示でも「お題文あり」と答えすぎた（適合率 0.2〜0.5）．32B が必要であった．推論型の 32B-Thinking はわずかに良い（0.78，0.76）が，約 6 倍遅い
全体の構成	現在のパッケージの F1 は，最終評価用 0.74，実データ 0.74 である．最も良い構成（現在の生徒＋学習し直した生徒を穴埋め・カルタの画像に使う）は 0.79，0.75 であった．ただし，実データの 95% 区間はどれも重なる（幅は約 ±0.1）
全データでの影響	お題文ありの割合は 8.3% から 10.2% に増える（穴埋め・カルタの画像に 1.9%）．属性から逆算した形式の正解率は，現在とほぼ同じである（最終評価用 0.931 → 0.928，実データ 0.950 → 0.952）
処理時間	推奨の構成は Qwen を使わない．現在の確認の質問（約 5〜7 時間）が不要になる．追加の生徒は保存済みの埋め込みに MLP を適用するだけである

2. 定義と正解

2.1 定義書 v5 の案

`programs/label_guideline/label_definition_v5.md` に案を作った．主な点は次のとおりである．

- 属性（複数）：カルタ記号あり，空欄あり，お題文あり，文字あり．
- 媒体（複数）：第 4 版と同じ 7 項目．
- 形式：属性から導く．カルタ記号あり→カルタ，空欄あり→穴埋め，お題文あり→お題文，それ以外→通常の順である．第 4 版の形式の優先順位と同じなので，第 4 版の形式の値と互換である．
- お題文あり：投稿者が回答者に向けて書き加えた，大喜利の題となる文である．

  - 問い，指示，題目の句，状況の設定，テンプレートや無地の背景に書いた主題の文（台本，手紙の書き出しなど）を含む．
  - 次のものはお題文としない．
    * 空欄を含む文そのもの．空欄を含む文章のまとまり（段落，説明文，字幕，歌詞など）は全体を空欄を含む文とみなす．
    * 元の素材にある文字．
    * 絵の中の吹き出しの台詞．

2.2 正解の作成

正解は，定義書 v4 の目視のラベル 1,020 枚から次のように作った．

- 形式がお題文の画像はお題文あり，通常の画像はお題文なしとした．第 4 版の定義から，そのまま決まる．
- 穴埋め･カルタの画像 328 枚は，Claude Code が目視で付け直した（`programs/ex024_odaibun_attr/odaibun_relabel.txt`）．
  - お題文ありは 30 枚（穴埋め 259 枚中 30 枚，カルタ 69 枚中 0 枚）であった．
  - 例：「世の中で弱いものは？ 1 位 赤ちゃん … 523 位□」，「初めてアルウィンに来たオルゴ・デミーラ様!! 最初に放った一言とは…!?」と空の吹き出し，「アンパンマンが負けたとき・水で襲ってきた・八百長・□」．
  - 判断に迷った境界の例をメモに残した．
    * 絵の中の吹き出しの台詞（4 枚）はお題文なしとした．
    * 説明文の中の空欄（8 枚）と歌詞（5 枚）は，元からある文章としてお題文なしとした．
    * テンプレートに書いた台本（4 枚）はお題文ありとした．

表 1：正解の正例の枚数．

集合	枚数	お題文あり	うち穴埋めの画像
調整用（評価用データの dev）	320	43	8
最終評価用（評価用データの test）	320	44	10
実データ（無作為 160 枚＋層別 220 枚，重み付き）	380	39	12

3. Qwen の指示とモデルの比較

3.1 指示

指示	内容
P0	現在の確認の質問（英語．「投稿者が回答者に向けて主題として書いた文があるか」）
P1	お題文ありの定義（含むもの，含まないもの）を日本語で与え，真偽を答えさせる
P1en	P1 の英語版
P2	画像中の文を最大 6 つ書き出させ，文ごとに空欄の有無・出どころ・種類を答えさせ，規則で判定する
P3	P1 に，空欄を含む文章のまとまりの規則と，判断の手順（投稿者の文字を分ける →空欄を含むまとまりを除く →残りに問い等があるか．迷えばなし）を加える
P4	P3 で，お題文に当たる文を書き写させる（出力が崩れることがあり，採用しない）

P3 は，調整用の集合での P1 の誤りを見て作った．そのため，調整用の集合の値は高めに出る．

3.2 結果

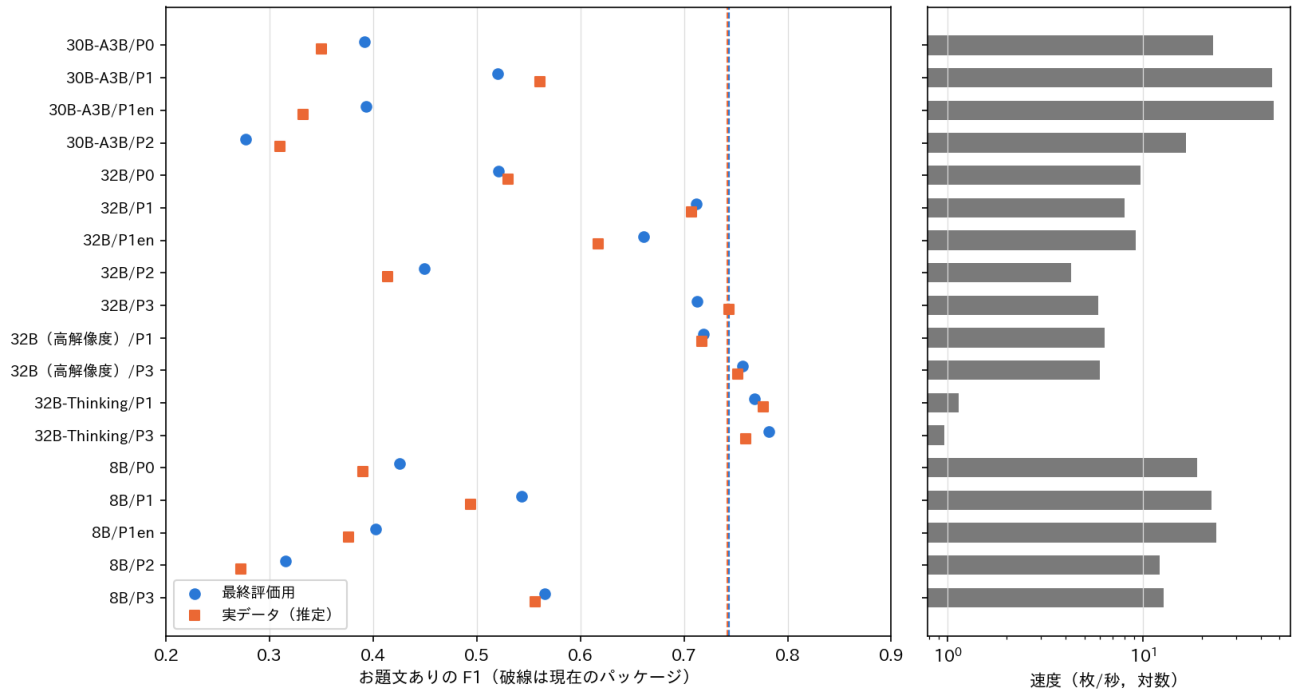


図 1　モデルと指示ごとのお題文ありの F1（左）と速度（右）

表 2：主な設定の F1（適合率／再現率）．速度は RTX PRO 6000 での 1,020 枚の推論の値である．

モデル・指示	速度（枚/秒）	調整用	最終評価用	実データ
現在のパッケージ（参考）	—	0.88（0.95/0.81）	0.74（0.85/0.66）	0.74（0.82/0.68）
8B・P0（現在の確認の質問）	18.9	0.46（0.30/1.00）	0.43（0.27/1.00）	0.39（0.24/1.00）
8B・P3	12.7	0.68（0.51/1.00）	0.57（0.42/0.89）	0.56（0.39/0.96）
30B-A3B・P1	45.7	0.71（0.56/0.95）	0.52（0.40/0.75）	0.56（0.41/0.88）
32B・P0	9.7	0.59（0.41/1.00）	0.52（0.35/1.00）	0.53（0.36/1.00）
32B・P1	8.0	0.83（0.76/0.93）	0.71（0.62/0.84）	0.71（0.59/0.89）
32B・P3	5.9	0.89（0.91/0.88）	0.71（0.72/0.70）	0.74（0.70/0.79）
32B・P3（高解像度）	6.0	0.89（0.87/0.91）	0.76（0.82/0.70）	0.75（0.72/0.79）
32B-Thinking・P3	1.0	0.89（0.93/0.86）	0.78（0.79/0.77）	0.76（0.76/0.76）
32B-Thinking・P1	1.1	0.86（0.80/0.93）	0.77（0.69/0.86）	0.78（0.69/0.88）

- 高解像度は，入力の上限を 448×448 画素から 896×896 画素相当に上げたものである．
- 32B-Thinking は出力を JSON に制約しないで生成した．約 3% は答えを読み取れず，「なし」として数えた．

考察：

- **小さなモデルの限界**：8B と 30B-A3B は，定義を詳しく与えても「お題文あり」と答えすぎた．調整用の集合の誤りを見ると，次の 3 種類が多かった．
  - 空欄を含む文そのもの（例：「部屋と□とわたし」）
  - テレビの字幕
  - 漫画の台詞
- **32B と指示**：32B は定義の除外の条件を守れた．P0 から P3 への変更で，最終評価用の F1 が 0.52 から 0.71〜0.76 に上がった．
- **文を書き出す指示**：文を書き出して規則で判定する指示（P2）は，どのモデルでも悪かった．書き出しの漏れや，出どころの誤りが判定に直接響くためと考えられる．
- **全画像に Qwen を使う構成**：32B を全画像に使うと，約 661 万枚に約 12.8 日（6 枚/秒）かかる．現実的でないため，教師ラベルとして生徒に移す．

4. 生徒の学習し直しと全体の構成

4.1 生徒

- 教師：32B・P3（高解像度）で，現在の生徒の教師ラベルの画像 4.5 万枚にお題文ありを付けた（`teacher.py`）．
  - 現在の生徒の文字ありの確率が 0.3 未満の画像は，質問せずにお題文なしとした．
  - 質問したのは 26,577 枚で，約 75 分かかった．お題文ありは 4,364 枚（4.5 万枚の 9.7%）であった．
  - 目視のラベルでお題文ありの画像は，全て文字ありの確率が 0.99 以上であった．
- 生徒：パッケージの埋め込み（SigLIP2-so400m，1,152 次元）に，お題文ありの出力層を持つ MLP を付けた（`train.py`）．
  - 比べた入力：埋め込みのみ（emb），埋め込み＋現在の生徒の形式・属性の確率（emb+probs）．
  - 学習率：1e-3，3e-4．各 3 seed．
  - 調整用の集合の F1 で，emb+probs，学習率 1e-3（0.93）を選んだ．閾値は 0.3 である．
  - 学習用の誤差は下がり続けるが，検証用の誤差は 2〜4 エポック目で最小になり，その後は過学習した．検証用の誤差が最小のエポックの重みを用いた．検証用での教師との一致は F1 約 0.80 である．

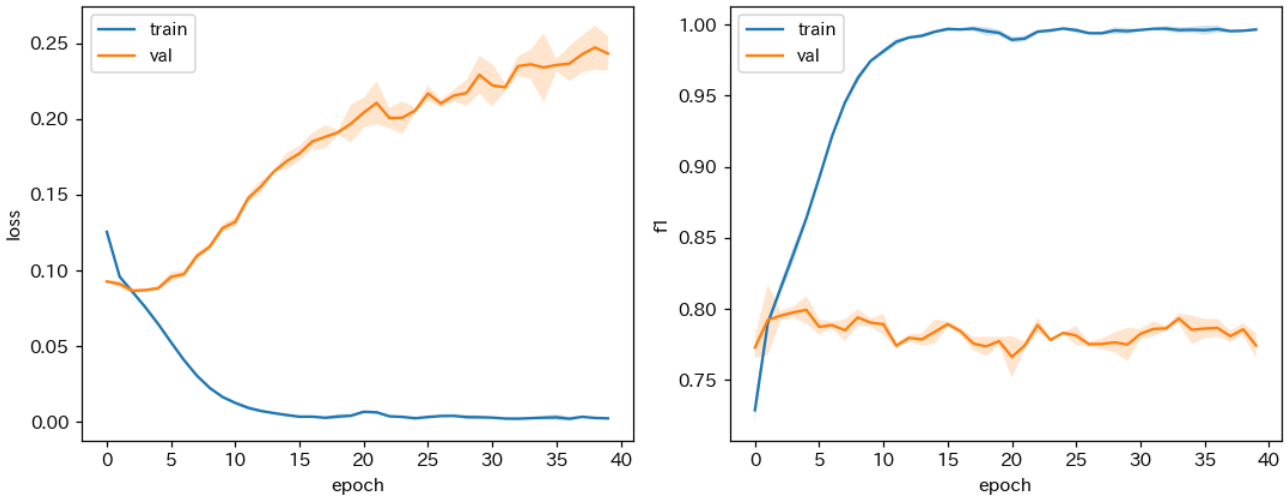


図 2　生徒（emb+probs，学習率 1e-3）の学習曲線．3 seed の平均と標準偏差

- 埋め込みはパッケージが保存したものを用いた．そのため，画像を読み直さずに学習でき，全データ 661 万枚にも適用できる．

4.2 構成の比較

構成	内容
現在のパッケージ	形式がお題文の画像をお題文ありとする．穴埋め・カルタの画像にはお題文ありが付かない
Qwen（全画像）	32B・P3（高解像度）を全画像に問う（参考．全データには適用できない）
生徒（学習し直し）	新しい生徒の確率が 0.3 以上
生徒＋ Qwen	生徒の確率が中間の帯（調整用の集合で決めた 0.2〜0.3）の画像だけ Qwen に問う
現在＋生徒（穴埋め・カルタ）	空欄・カルタ記号のない画像は現在のパッケージの判定を使う．穴埋め・カルタと予測した画像は，新しい生徒の判定を使う
現在＋生徒＋ Qwen（穴埋め・カルタ）	上の構成で，穴埋め・カルタの画像は，生徒の確率が 0.2 以上かつ Qwen が真の場合にお題文ありとする

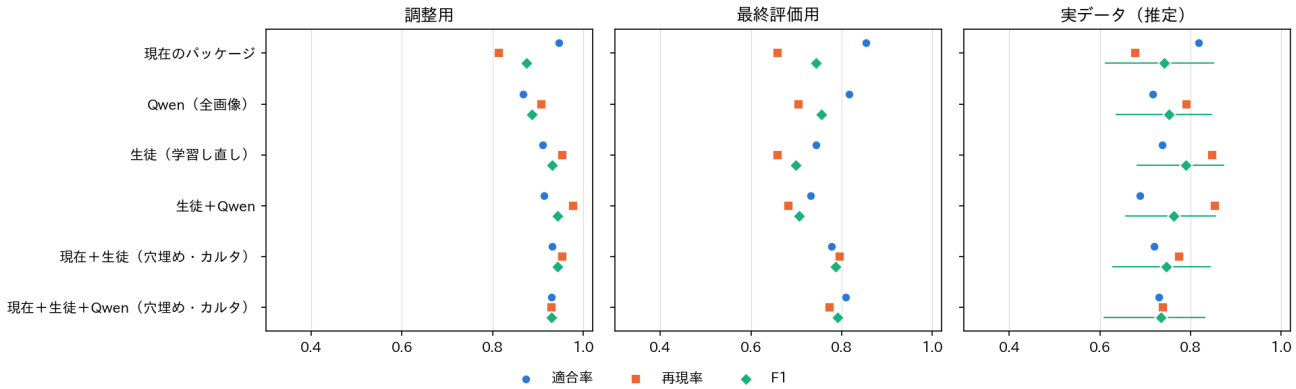


図 3　構成ごとのお題文ありの適合率・再現率・F1．横線は実データの F1 の 95% 区間

表 3：構成ごとの適合率／再現率／ F1.

構成	調整用	最終評価用	実データ	実データの F1 の 95% 区間	全データで Qwen に問う割合
現在のパッケージ	0.95/0.81/0.88	0.85/0.66/0.74	0.82/0.68/0.74	0.61 – 0.85	8.3%（現在の確認の質問）
Qwen（全画像）	0.87/0.91/0.89	0.82/0.70/0.76	0.72/0.79/0.75	0.63 – 0.85	100%
生徒（学習し直し）	0.91/0.95/0.93	0.74/0.66/0.70	0.74/0.85/0.79	0.68 – 0.87	0%
生徒＋ Qwen	0.91/0.98/0.94	0.73/0.68/0.71	0.69/0.85/0.76	0.66 – 0.86	1.5%
現在＋生徒（穴埋め・カルタ）	0.93/0.95/0.94	0.78/0.80/0.79	0.72/0.77/0.75	0.63 – 0.84	0%
現在＋生徒＋ Qwen（穴埋め・カルタ）	0.93/0.93/0.93	0.81/0.77/0.79	0.73/0.74/0.73	0.61 – 0.83	2.7%

- 「現在＋生徒」の 2 つの構成は，最終評価用と実データの結果を見た後に加えた．そのため，両集合での値はやや楽観的である．
- 現在のパッケージの「Qwen に問う割合」は，現在の確認の質問の対象（形式がお題文と予測した代表の画像）の割合である．

考察：

- **最終評価用と実データで異なる傾向：**新しい生徒は，実データでは最も良い（0.79）が，最終評価用では最も悪い（0.70）．
  - 最終評価用の集合は，少ない区分の画像（文字が主体の画像など）を多く含む．新しい生徒は，その中の形式がお題文の画像を見逃した．
  - 現在の生徒は，形式がお題文の画像（空欄なし）では，最終評価用でも実データでも適合率・再現率が 0.82〜0.85 と安定している．
- **推奨の構成：**「現在＋生徒（穴埋め・カルタ）」は，両集合で現在より良く（0.79，0.75），Qwen を必要としない．
  - 空欄なしの画像では，現在の生徒の安定した判定をそのまま使う．
  - 穴埋め・カルタの画像では，新しい生徒が問いの文を拾う．
- **Qwen の確認の効果：**穴埋め・カルタの画像で Qwen に確認させても，最終評価用の適合率がわずかに上がるだけで，実データの再現率は下がった．
- **改善の幅：**改善は最終評価用で 0.05，実データで 0.01 にとどまり，95% 区間の幅（約 ±0.1）より小さい．評価用の正例が各集合で約 40 枚と少ないため，構成の差を統計的に確かめられていない．

4.3 属性から逆算した形式

推奨の構成のお題文ありと，現在のパッケージの空欄あり・カルタ記号ありから形式を逆算し，定義書 v4 の形式と比べた．

表 4：形式の正解率と，お題文の適合率／再現率．

方法	集合	形式の正解率	お題文	穴埋め	通常
現在のパッケージ	最終評価用	0.931	0.85/0.85	0.91/0.96	0.95/0.95
逆算	最終評価用	0.928	0.87/0.79	0.88/0.99	0.96/0.94
現在のパッケージ	実データ	0.950	0.82/0.83	0.95/0.93	0.96/0.97
逆算	実データ	0.952	0.82/0.83	0.93/0.97	0.97/0.96

形式の精度は，現在とほぼ同じである．最終評価用で形式のお題文の再現率が下がったのは，現在の生徒が形式をお題文と予測しつつ空欄ありの確率も 0.5 以上とした画像（2 枚）が，逆算では穴埋めになるためである．

5. 未解決の論点と次の候補

1. **パッケージへの組み込み：**推奨の構成を組み込むには，次を行う．
   - 生徒に「お題文あり」の出力層を加える（今回の MLP の重みを用いる）．
   - 属性の出力に `has_odai_text` を加え，形式を属性から導く．
   - 確認の質問の段階を外す．
   - 全データの画像の予測し直しは不要である．保存済みの埋め込みと確率から計算できる．
2. **お題文の精度の上限：**F1 は 0.75〜0.79 で頭打ちである．次の 2 つが要因と考えられる．
   - 境界の例（説明文の中の空欄，テンプレートの台本，吹き出しの台詞）の判断の難しさ．

- 正解が Claude Code 1 人の目視のラベルであること．
- 目視のラベルの再現性（付け直しの一致率）を測ると，到達できる上限が分かる．

3. **評価の正例の不足**：正例が各集合で約 40 枚と少なく，構成の差を確かめられない．お題文ありの候補を多く含む層別抽出で，正例を 200 枚程度に増やすことが望ましい．
4. **教師の改善**：推論型の 32B-Thinking は，教師としてわずかに良い可能性がある．ただし，2.7 万枚に約 7.5 時間かかる．
5. **定義書 v5 の確定**：境界の扱いを確定させる．特に「元からある説明文の中の空欄」と「投稿者が作った説明文」の区別である．

付録

- プログラム：`programs/ex024_odaibun_attr/`
  - `data.py`：正解（お題文ありの付け直しを含む），集合と重み，パッケージの埋め込みの読み込み．
  - `make_sheets.py`：付け直しの一覧の画像（`datasets/ex024_odaibun_attr/sheets/`）．
  - `odaibun_relabel.txt`：穴埋め・カルタの画像 328 枚のお題文ありの目視のラベル．
  - `qwen_odaibun.py`：Qwen の指示とモデルの比較（P0〜P4．`--reparse` で保存済みの出力を解釈し直す）．
  - `evaluate_prompts.py`：指示とモデルごとの適合率・再現率・F1 と図．
  - `teacher.py`：4.5 万枚の教師ラベル．
  - `model.py`，`train.py`：お題文ありの生徒（MLP）．
  - `evaluate_pipeline.py`：構成の比較，全データへの適用，形式の逆算．
- 定義書の案：`programs/label_guideline/label_definition_v5.md`
- 出力：`outputs/ex024_odaibun_attr/`
  - `qwen/{モデル}__{画素}/`，`prompt_metrics.csv`，`fig_prompts.png`
  - `teacher/`，`student/`
  - `pipeline/`（`metrics.csv`, `format.csv`, `config.json`, `student_all__*.parquet`, `fig_pipeline.png`）