report_045：お題文ありの既定の規則の決定（R1b，重ねた文字の問いを含める）

1. 概要

定義書 v6 の草案（report_044）で残していた，お題文ありを導く規則の 2 つの選択を決めた．

- 既定の規則を R1 から R1b に変えた．R1b は，余白の文字のその他の文を，同じ余白の文字に空欄を含む文がない場合に限ってお題文ありの根拠とする．
- 重ねた文字の問い・指示・題目の句は，元の放送の字幕か投稿者が加えたものかによらずお題文ありに含める．

定義書の 4 節を書き換え，ex026 のコードに R1b を正式な規則として加えて評価をやり直した．目視のラベルは付け直していない．パッケージは変更していない．

主な結果は次のとおりである．

- R1b で導いたお題文ありと v5 の目視のお題文ありの一致は，全データの推定で 98.5%（κ 0.90）であり，R1（97.3%，κ 0.84）より高い．
- R1b を正解とした導いたお題文ありの F1（全データの推定）は，v5.3.0 で 0.83 [0.79, 0.86]，属性を経る生徒（埋め込み＋ YomiToku）で 0.77，直接学習の生徒（埋め込み＋ 32B の書き起こし）で 0.79 であった．R1 を正解とした場合（それぞれ 0.79，0.76，0.78）と大きくは変わらない．
- 選択の前の説明で示した，重ねた文字の問いの件数は誤っていた（3 節）．正しくは，1,620 枚で重ねた文字に問い・指示・題目の句がある画像 53 枚のうち，v5 でお題文ありは 18 枚，お題文なしは 35 枚である．全データの推定では，含める場合と含めない場合の v5 との一致はほぼ同じ（κ 0.904 と 0.906）である．

2. 決めた規則

既定の規則（R1b）は次のとおりである．

- 重ねた文字または余白の文字に，問い・指示・題目の句のどれかがある．
- または，余白の文字にその他の文があり，同じ余白の文字に空欄を含む文がない．

規則の選択肢として，R0（余白のその他の文を含めない），R1（余白のその他の文を空欄の有無によらず含める），R2（R1 に重ねた文字のその他の文を加える）を残した．規則は属性から計算するため，属性を付け直さずに変更できる．

2.1 R1b を既定とした理由

余白の文字で，空欄を含む文とその他の文が並ぶ画像では，その他の文の多くが空欄を埋めるための見出しである．例えば，キャラクターの紹介の画面の名前，「なぞかけ」「ことわざ」の名札，映画の題名がこれにあたる．R1 ではこれらがお題文ありとなる．

1,620 枚で R1 と R1b が分かれた画像は 34 枚（すべて余白に空欄を含む文とその他の文がある画像）であった．そのうち 24 枚は v5 でお題文なしであり，R1b で v5 と一致するようになった．残りの 10 枚は v5 でお題文ありであり，R1b で一致しなくなった．この 10 枚は，写真の下の平叙文と空欄を含む題名，題名と筋と空欄の内容，名札と最後が空欄の列挙などである．v5 では空欄とは別に置いた状況の文や見出しをお題文ありの根拠としていたが，R1b ではこれらが問い・指示・題目の句の形でない限り根拠にならない．

2.2 重ねた文字の問いを含めた理由

投稿者が写真に重ねた問いと元の放送の字幕の問いは，見た目で区別できない．v6 は誰が書いたかを判定に用いないため，文の形だけで決める．含めない場合，投稿者が加えた問い（「〜何が有った？」など）を失う．

3. 選択の前の説明の訂正

選択の前の説明では，「重ねた文字の問いの画像 38 枚のうち約 23 枚は v5 でお題文あり，約 15 枚はお題文なし」とし，含める方が誤りの件数が少ないとした．これは誤りであった．評価の後に数え直した結果を表 1 に示す．

表 1：重ねた文字に問い・指示・題目の句がある画像（1,620 枚）．

v5 のお題文あり	画像の数	問い	指示	題目の句
あり	18	8	7	4
なし	35	30	4	1

v5 でお題文なしの 35 枚の多くは，アニメや映画の台詞の字幕が問いの形になったもの，テレビの字幕の問い，問いの形の番組名や題名である．1,620 枚では，含める方が v5 と食い違う画像が多い．

一方，全データの推定では差が小さい（表 2）．重ねた文字の問い・指示・題目の句がある画像は全体の 0.65% であり，v5 でお題文ありが 0.28%，お題文なしが 0.37% である．1,620 枚は v5 の誤りが疑われる画像を多く選んだ集合であるため，全データより食い違いが多く出る．

表 2：v5 の目視のお題文ありとの一致（全データの推定）．

規則	一致	κ	v6 の陽性率	v5 のみ陽性	v6 のみ陽性
R1b（重ねた文字の問いを含める，既定）	98.5%	0.904	8.95%	0.23%	1.26%
R1b から重ねた文字の形を除く	98.6%	0.906	8.31%	0.52%	0.89%
R1（参考）	97.3%	0.839	10.31%	0.15%	2.52%

v5 の陽性率は 7.93% である．

v5 との一致で見れば，2 つの選択はほぼ同じである．含めるかどうかは，「台詞の字幕が問いの形のものをお題文ありとしてよいか」で決めることになる．含めない場合は，投稿者が加えた問い（全データの 0.28%）を失う．訂正の後も既定は含める側のままとしたが，規則は属性から計算するため，後から変更できる．

4. 導いたお題文ありの精度

R1b を正解とした導いたお題文ありの精度を表 3 に示す（ex025 の 600 枚の層の重みによる全データの推定）．

表 3：導いたお題文ありの F1（正解は v6 の目視から R1b で導いたもの）．

手法	適合率	再現率	F1	95% 区間
v5.3.0	0.781	0.881	0.828	[0.79, 0.86]
Qwen3-VL-32B（V6）	0.282	0.943	0.434	[0.36, 0.53]
生徒（属性を経る，埋め込み）	0.552	0.790	0.650	[0.55, 0.76]
生徒（属性を経る，埋め込み＋ YomiToku）	0.733	0.817	0.773	[0.70, 0.84]
生徒（直接学習，埋め込み＋ 32B の書き起こし）	0.687	0.914	0.785	[0.67, 0.89]

v5.3.0 は R1 を正解とした場合（0.79）より高い．R1b は v5 の定義に近いためである．生徒の順位と，v5.3.0 に届かないという report_044 の結論は変わらない．1,620 枚での直接学習（R1b）の学習曲線は，埋め込みで 0.64（162 枚）から 0.71（1,296 枚），埋め込み＋文で 0.65 から 0.74 であり，まだ伸びている．

5. 変更したファイル

- `programs/label_guideline/label_definition_v6.md`：4 節（既定の規則を R1b とし，重ねた文字の問いを含める理由，第 5 版との違い），改訂履歴．
- `programs/ex026_text_attr_v6/data.py`：`add_derived` に `odai_R1b` を加えた．
- `programs/ex026_text_attr_v6/evaluate.py`：規則の一覧に R1b を加え，v5 と R1b の食い違いの一覧（`definition_diff_R1b.csv`）を出力し，学習曲線の対象を R1b とした．
- `outputs/ex026_text_attr_v6/eval/`：評価の出力を作り直した．
- `visualize_result.ipynb`：ex026 の表示の既定の規則を R1b とした．

6. 今後の課題

- 台詞の字幕が問いの形のものをお題文ありとするかは，3 節のとおり v5 との一致では決まらない．大喜利の題としての使われ方（回答が問いに答えているか）で確かめる余地がある．
- v6 への移行の主な障害は，report_044 のとおり，教師ラベル（Qwen の属性）の精度である．