report_046：お題画像の文字の扱いとその影響をまとめた論文の作成

1. 概要

お題画像の中の文字の扱いについて，定義書の改訂の経緯と，各段階の定義がラベルの付与に与えた影響をまとめた和文の論文（TeX）を作成した．論文は `paper_text/` に置き，`latexmk -pdfdvi -synctex=1 main.tex` で `paper_text/main.pdf`（ieicejsp の二段組，8 ページ）を生成した．投稿先とページ数の指定がなかったため，既存の論文 `paper/` と同じ体裁で 8 ページとした．新しい実験は行っていない．ただし，図と数値の一部は保存済みの目視のラベルと評価の出力から計算し直した（2 節）．

- 対象：投稿先，締切，ページ数の制限は未指定．
- 題目：大喜利のお題画像における文字の扱いとその影響：投稿者の意図による定義から見て決められる文の属性へ．
- 主張：
  - 文字ありは，改訂のたびに観測できる基準に近づいた．
  - お題文は投稿者の意図に基づく定義を保ったため，誤りが文字の出所の判断に集中した．
  - そこで文の属性（層と形）から規則で導く定義（第 6 版）を提案した．
  - 提案の定義は，再現性と v5 との一致を保ち，規則の選択による違いを明示できる．
  - 一方，教師の層の精度が移行の障害である．

2. 論文の構成と材料

章	内容	主な材料
1 はじめに	文字の役割と，意図に基づく定義の問題	—
2 データと用語	682 万件のお題，代表の画像，3 軸のラベル，蒸留，目視ラベル	paper/ の 2 章
3 関連研究	大喜利とユーモア，情景の文字の VQA，ラベルの揺れ，蒸留	—
4 文字の扱いの変遷	第 1 版〜第 6 版の文字ありとお題文の扱い（表 1）	paper/ の 6 章，report_012，report_041〜042
5 意図に基づく定義の影響	層別抽出と重みによる推定（式 1），確認の質問，第 5 版の教師の比較（表 2），v5.3.0 の評価と残った誤り	report_012，report_040〜043
6 文の属性による定義	層と形の定義，例の図（図 1），規則 r0，r1，r1b，r2 の式（式 2，式 3），比較の規則 r1b′	label_definition_v6.md，report_045
7 評価の方法	1,620 枚の目視ラベル，教師（32B），生徒（ロジスティック回帰），図 2	report_044
8 結果	属性の頻度と再現性，規則とお題文ありの割合（表 3），属性の F1（図 2），導いたお題文ありの F1（表 4），学習曲線（図 3），書き起こしの費用（表 5）	ex026 の出力，report_044〜045

章	内容	主な材料
9 考察	観測可能性と再現性，規則の選択の影響，教師と生徒，限界	—
10 おわりに	まとめと今後の課題	—

図と数値は `programs/paper_text/make_figures.py` で作った（出力は `outputs/paper_text/`．論文の図は `paper_text/figures/` に複製）．

- `numbers.json`：
  - 規則ごとの v5 との一致：r1b′（重ねた文字の形を除く規則）を含む．
  - 付け直しの一致：r1b を含む．ex026 の `repeat.csv` は evaluate.py では作られていなかったため，ここで計算し直した．
  - 重ねた文字の問いの枚数と，R1 と R1b で分かれる画像の枚数．
  - 層と形の頻度：全データの推定を含む．
- `fig_examples.png`：層と形の例の 8 枚．1,620 枚の通し番号 8，50，109，841，1080，199，638，100．
- `fig_attrs.pdf`：属性ごとの F1．教師と，生徒 2 種（埋め込み，埋め込み＋ YomiToku）．
- `fig_curve.pdf`：学習曲線．余白の文字，お題文あり（R1b），問い，その他の文．

図 1 に論文の 1 ページ目を，図 2〜4 に論文の図を示す．

大喜利のお題画像における文字の扱いとその影響：投稿者の意図による定義から見て決められる文の属性へ

Handling Text in Ogiri Prompt Images and Its Effects: From Poster-Intent Definitions to Observable Text Attributes

山富 龍
Ryo Yamatomi

湘南工科大学 大学院
Graduate University of Shonan Institute of Technology

概 要

大喜利投稿サイト「ボケて」のお題画像の約 6 割には読める文字があり，その文字が回答者への題であるか，画像の素材の一部であるかによって，ボケの生成に必要な処理が変わる．本稿では，約 682 万件のお題画像へのラベルの付与において，画像中の文字をどのように定義し，その定義がラベルの再現性，教師となる視覚言語モデル (Vision-Language Model，VLM) と生徒となる分類器の精度，全データのラベルの分布にどのような影響を与えたかを報告する．従来の定義では，お題文を「投稿者が回答者に向けて書き加えた文」とし，元の素材の字幕や看板を除いていた．この定義の下では，誤りの多くがテロップや帯の文字の出所の判断に集中し，VLM は投稿者が加えた文と元の字幕を区別できなかった．そこで，文字を写っている場所による 4 つの層と，文の形による 5 つの形に分け，お題文の有無を属性から規則で導く定義を提案した．1,620 枚の目視ラベルで評価した結果，提案の属性は付け直しで記号の 94%が完全に一致し，選んだ規則で導いたお題文の有無は従来の定義と全データの推定で 98.5%（Cohen の κ 0.90）一致した．また，規則を変えるだけで，お題文と判定される画像の割合が 7.4%から 16.7%まで変わることを示した．一方，Qwen3-VL-32B は層を区別できず，教師としての F1 は 0.43 にとどまり，1,620 枚で学習した生徒も既存のパッケージの F1 0.83 に届かなかった．

キーワード 大喜利，データアノテーション，ラベル設計，視覚言語モデル，画像中の文字

Abstract

About 60% of the prompt images on the Japanese Ogiri site Bokete contain readable text, and whether the text is a prompt addressed to the answerers or part of the source material changes the processing needed to generate a witty response. This paper reports how we defined text in prompt images when annotating about 6.82 million images, and how the definition affected label reproducibility, the accuracy of a vision-language model (VLM) teacher and a student classifier, and the label distribution of the whole dataset. The previous definition treated a prompt sentence as text added by the poster for the answerers and excluded captions and signs in the source material. Under this definition, most errors concentrated on judging the origin of captions and bands, and the VLM could not distinguish text added by the poster from original subtitles. We therefore propose to split text into four layers by where it is placed and five forms by its sentence form, and to derive the presence of a prompt sentence from these attributes by a rule. On 1,620 manually labeled images, 94% of the attribute codes were reproduced exactly on relabeling, and the presence of a prompt sentence derived by the selected rule agreed with the previous definition on 98.5% of the population (Cohen's κ 0.90). We also show that changing the rule alone moves the share of images with a prompt sentence from 7.4% to 16.7%. However, Qwen3-VL-32B could not distinguish the layers and reached an F1 of only 0.43 as a teacher, and students trained on the 1,620 images did not reach the F1 of 0.83 of the existing package.

Key words Ogiri, Data Annotation, Label Design, Vision-Language Model, Text in Images

1 はじめに

大喜利は，出題された題目に対して機知に富んだ回答を返す言葉遊びである．大喜利投稿サイト「ボケて」[1] では，投稿者がお題となる画像を掲示し，他の利用者がその画像に対する面白い一言を投稿する．以下では，お題となる画像をお題画像，利用者が投稿する一言をボケと呼ぶ．ボケてに蓄積されたお題画像とボケの組は，画像を入力として面白い文を生成するモデルの学習や，ユーモアの分析に利用できる大規模な資源である．これらの用途では，各お題画像がどの種類に属するかを示すラベルが必要になる．本研究では，約 682 万件のお題画像にラベルを付与する方法を構築してきた．

お題画像の扱いを最も難しくしている要素は，画像中の文字である．お題画像の約 6 割には読める文字がある．その文字には，投稿者が回答者に向けて書いた問いや指示もあれば，写真に写った看板，テレビの字幕，漫画の台詞のように，素材に元からある文字もある．回答者にとって前者は答えるべき題であり，後者は一言を付ける対象の一部である．したがって，ボケの生成では，文字を読み取るかだけでなく，読み取った文字を題として扱うかを決める必要がある．

従来のラベルでは，題として扱う文字を「お題文」と

図 1 論文の 1 ページ目（paper_text/main.pdf）.

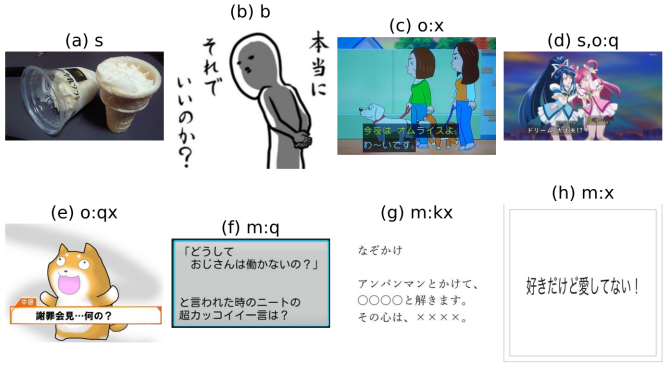


図 2 層と形の例（論文の図 1）．(a) 商品の表示，(b) 人物の脇の台詞，(c) アニメの字幕の台詞，(d) アニメの字幕の問い，(e) テロップ風に書き加えた問い，(f) 枠の中の問い，(g) 名札と空欄を含む文，(h) 無地の背景の平叙文．

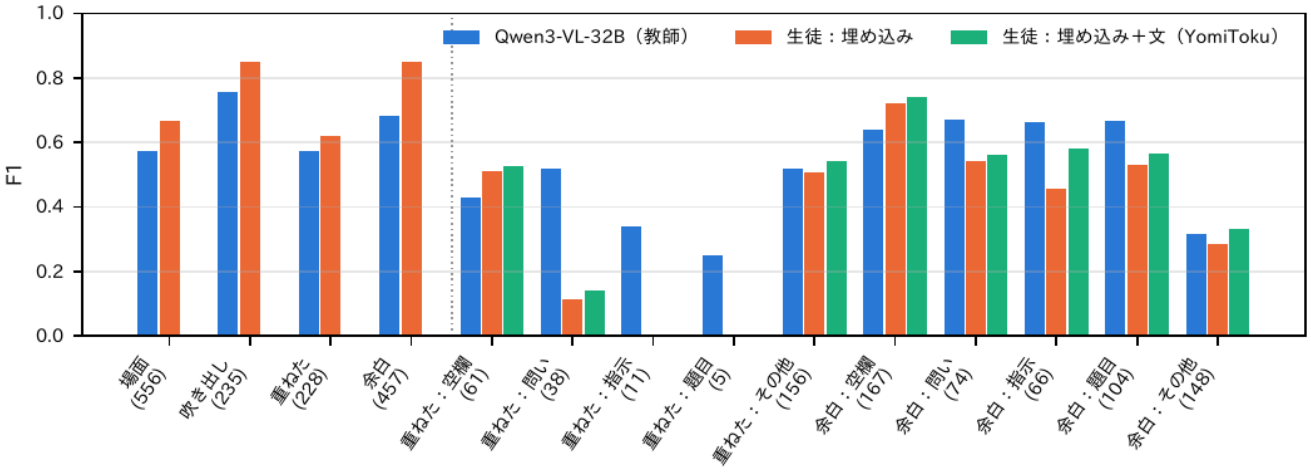


図 3 属性ごとの F1（論文の図 2．1,620 枚，生徒は 5 分割の分割外の予測）．

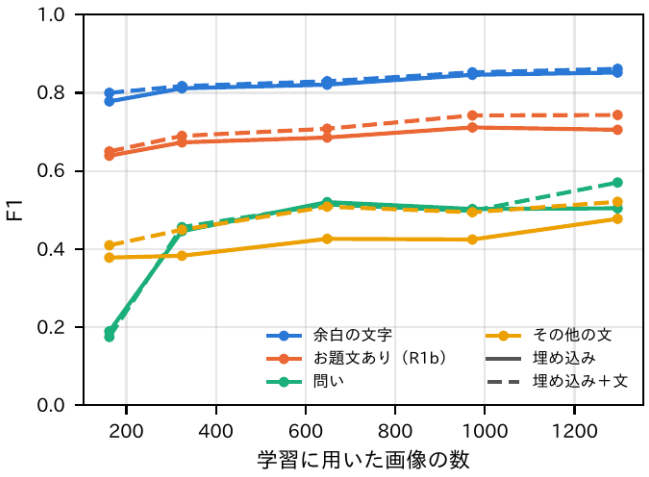


図 4 学習曲線（論文の図 3）．

論文で新たに示した主な数値は次のとおりである（report_045 までに示した値は省く）．

- 全データの推定での層の頻度：場面の文字 35.0%，吹き出し 14.3%，重ねた文字 8.3%，余白の文字 12.1%．いずれかの層は 58.7% であり，パッケージの文字ありの割合（387.8 万枚／ 661 万枚）と一致した．
- 付け直しの一致：R1b のお題文ありの κ は 1.00 であった（R1 は 0.97，R2 は 0.92）．

3. 確認した事項

- コンパイルの警告：未定義の参照と Overfull はない．caption パッケージの文書クラスに関する警告は既存の論文と同じであり，体裁には影響しない．
- PDF の目視：図表の位置，表のはみ出しを確認した．全幅の図 2 は，「評価の方法」の章の冒頭で定義した．これは，結果の章と同じページの上部に置くためである．
- 規約：
  - である調と「,.」を用いた．
  - 図のキャプションは図の下に，表のキャプションは表の上に置いた．
  - ラベルは fig_／tab_／eq_ で付け，章と節までで構成した．
  - 略称は初出で正式名称とともに記した．VLM，MLP，OCR，TF-IDF である．
- `latexmk -C` は PDF も消すため実行していない．中間ファイル（main.dvi など）は既存の `paper/` と同じく残した．

4. 未解決の指摘事項と次の候補

- 投稿先とページ数：未指定である．投稿先が決まれば，体裁とページ数を合わせる必要がある．予稿の場合は，サンプルの ja_proceeding_03 または 04 を参考に，2〜4 ページに縮める．
- 既存の論文との重複：第 1 版〜第 4 版の経緯（4 章）は既存の論文 `paper/` の 6 章と重なる．両方を投稿する場合は，一方を引用する形に改める必要がある．
- 判断者：目視ラベルは全て同じ判断者（Claude Code）によるものであり，人どうしの一致は測っていない．論文では限界として記した．人の判断者による一致を測れば，この記述を置き換えられる．
- 重ねた文字の問いを含めるか：論文では，第 5 版との一致では決まらないことを示すにとどめた．ボケの内容（回答が問いに答えているか）で確かめる実験は未実施である．
- 教師の改善：層を生徒に任せ，教師には文の形だけを問う構成は提案にとどまり，実施していない．
- 著者と所属：既存の論文 `paper/` と同じ記載とした．共著者や謝辞が必要なら追記する．