report_050：写真・文字なしと写真・通常のお題画像の件数と判定精度

概要

現実の画像に対する大喜利の面白さの判定に向けて，お題画像を絞り込む 2 つの条件の件数と判定精度を求めた（ex029）．

- 条件 A「写真・文字なし」: パッケージ v5.3.0 の媒体が写真のみ（他の媒体を含まない）で，文字ありが偽．
- 条件 B「写真・通常」: 媒体が写真のみで，形式が通常（お題文・穴埋め・カルタでない）．

結果は次のとおりである．

- 件数（v5.3.0 の予測）: 条件 A はお題が約 201 万件（全体の 29.5%），ボケが約 2,129 万件（23.0%）であった．条件 B はお題が約 306 万件（44.9%），ボケが約 2,991 万件（32.3%）であった．
- 判定精度（実データの推定）:
  - 条件 A は，v4 の正解で適合率 1.00・再現率 0.92・F1 0.96，v6 の文字の正解で適合率 0.96・再現率 0.98・F1 0.97 であった．
  - 条件 B は，v4 の正解で適合率 0.98・再現率 0.99・F1 0.98，v6（R1b）の正解で F1 0.98 であった．
  - どちらの条件も，絞り込みに使うのに十分な精度である．
- 条件 A の再現率が v4 の正解で 0.92 にとどまったのは，v4 の目視の見落としが主な原因である．見逃し 11 枚のうち 9 枚は，v6 の付け直しで文字ありとされた（小さな透かし・看板など）．

方法

`programs/ex029_photo_subset/evaluate.py` で次を求めた．

- 件数 : annotation.parquet の全てのお題（682 万件．重複を含む）と代表の画像（661 万枚）について，v5.3.0 の予測で条件を判定した．ボケのアノテーション（約 9,249 万件）をお題ごとに数え，ボケの件数と画像外の知識の割合も求めた．
- 判定精度 : ex022 ／ ex023 で用いた 1,020 枚の Claude Code の目視のラベル（定義書 v4 の形式・属性・媒体）を正解とした．
  - 実データ（real）: 無作為抽出 160 枚と層別抽出 220 枚を重み付けした推定である．95% 区間は，抽出の群（無作為・層ごと）ごとに 2000 回の復元抽出をして求めた．
  - 評価用データ（eval）: 少ない区分を多く含む 640 枚の集合で，重みはない．
  - 同じ 1,020 枚には ex026 の定義書 v6 の文の属性がある．そこで，条件 A は文字ありを v6 の文字の層で付け直した正解でも，条件 B は v6 の規則 R1b で導いた通常の正解でも求めた．v6 の正解では，写真のみ・空欄あり・カルタ記号ありは v4 の目視を用いた．

結果

件数

表 1 : 条件ごとの件数（v5.3.0 の予測）．画像外の知識の割合は，パッケージのボケの判定による．

条件	お題	代表の画像	ボケ	お題の割合	ボケの割合	画像外の知識
全て	6,823,270	6,609,511	92,492,813	100%	100%	27.1%
写真のみ	3,474,756	3,371,140	38,207,617	50.9%	41.3%	28.6%

条件	お題	代表の画像	ボケ	お題の割合	ボケの割合	画像外の知識
条件 A：写真・文字なし	2,009,955	1,947,651	21,290,521	29.5%	23.0%	30.8%
条件 B：写真・通常	3,063,330	2,968,966	29,911,515	44.9%	32.3%	30.2%
A かつ B	1,945,548	1,884,236	20,421,755	28.5%	22.1%	31.0%

条件 A のほとんど（97%）は条件 B にも含まれる．A に含まれて B に含まれないのは，文字のない空欄や空の吹き出しだけの写真（形式が穴埋め）である．B に含まれて A に含まれないお題は約 112 万件ある．これは，看板・衣服の文字，透かし，字幕や台詞の文字がある写真である．

条件 A のお題 1 件あたりのボケは約 10.6 件である（全体は約 13.6 件）．条件 A と B のボケのうち，画像外の知識が要ると判定されたものは約 31% で，全体（27.1%）よりやや多い．

判定精度

表 2：条件ごとの判定精度．実データは重み付きの推定（括弧は 95% 区間），評価用データは 640 枚の重みなしの値である．正例の数は目視の正解の枚数．

条件（正解）	集合	正例	適合率	再現率	F1	正解の割合	予測の割合
写真のみ（v4）	実データ	149	0.95（0.93 – 0.98）	0.99（0.97 – 1.00）	0.97	48.9%	50.7%
条件 A（v4）	実データ	84	1.00（1.00 – 1.00）	0.92（0.86 – 0.97）	0.96	32.9%	30.1%
条件 A（v6 の文字）	実データ	73	0.96（0.90 – 1.00）	0.98（0.95 – 1.00）	0.97	29.6%	30.1%
条件 B（v4）	実データ	108	0.98（0.96 – 1.00）	0.99（0.96 – 1.00）	0.98	43.0%	43.3%
条件 B（v6 の R1b）	実データ	107	0.97（0.94 – 0.99）	0.99（0.96 – 1.00）	0.98	42.7%	43.3%
写真のみ（v4）	評価用	262	0.97	0.97	0.97	—	—
条件 A（v4）	評価用	161	0.99	0.89	0.94	—	—
条件 A（v6 の文字）	評価用	148	0.94	0.92	0.93	—	—
条件 B（v4）	評価用	201	0.98	0.97	0.98	—	—
条件 B（v6 の R1b）	評価用	200	0.98	0.98	0.98	—	—

誤りの内訳（実データ）は次のとおりである．

- **写真のみの誤検出（12 枚）**：多くは，写真にテキストグラフィック（スクリーンショットや文字の帯）を貼り合わせた画像であり，ほかにイラストのみの画像（2 枚）などがある．前者の多くは文字を含むため，条件 A では除かれる．
- **条件 A の見逃し（v4 の正解で 11 枚）**：全て，v5.3.0 が文字ありと判定した写真であった．そのうち 9 枚は，v6 の付け直しで文字ありとされた（小さな透かし，看板，衣服の文字など）．
- **条件 A の誤検出（v6 の正解で 4 枚）**：3 枚は，v6 の付け直しで場面の文字（看板など）だけがあるとした写真である．重ねた文字や余白の文字はないため，ボケを理解するのに文字を読む必要は小さい．残りの 1 枚は，v4 の目視で写真のみではないとした画像である．
- **条件 B**：v4 と v6（R1b）の正解で精度はほぼ同じであった．写真の通常の判定は，お題文の定義の変更の影響をほとんど受けない．

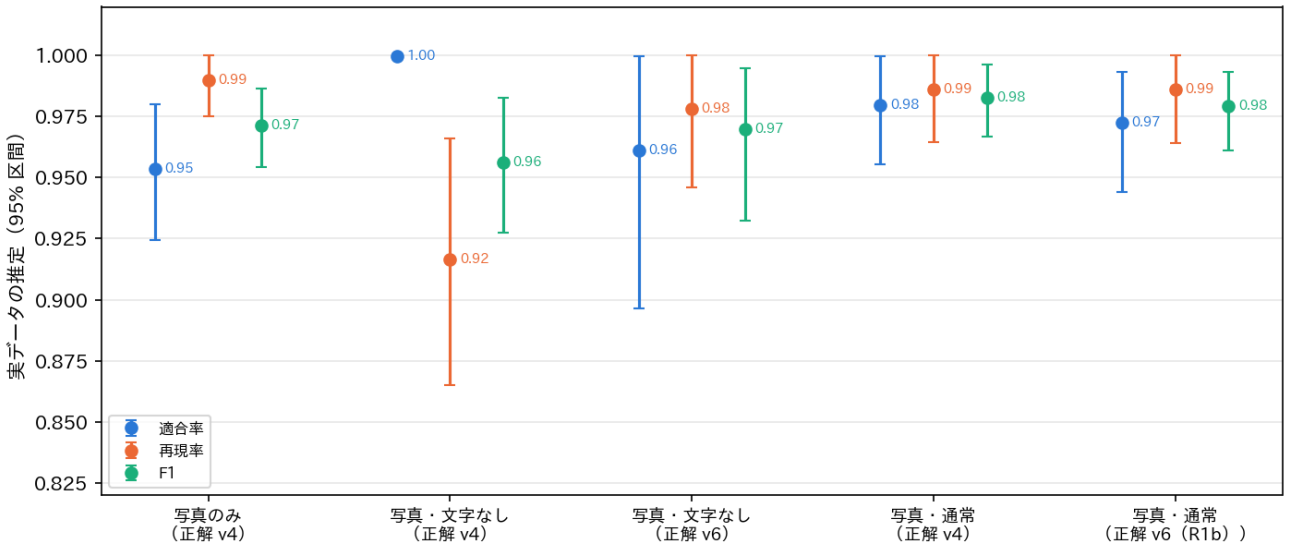


図 1　条件ごとの適合率・再現率・F1（実データの推定，95% 区間）．

考察

2 つの条件とも，v5.3.0 の予測で F1 0.96〜0.98 の精度で絞り込める．予測の割合（A 30.1%，B 43.3%）は，目視の推定の割合（A 29.6〜32.9%，B 42.7〜43.0%）とほぼ一致した．したがって，件数も信頼できる．

「文字の認識が要らない」という目的には，条件 A が合う．ボケの数は約 2,129 万件あり，学習や分析には十分な量である．条件 A の誤りは，ほとんどが場面の文字（透かしや小さな看板など）の有無の判断であり，読まなくても困らない文字である．目的を損なう誤り（字幕や台詞のある写真が混ざること）はほとんどない．一方，条件 B には字幕・台詞・看板の文字がある写真が約 112 万件（お題の約 3 分の 1）含まれる．文字の認識を避けたい場合は不向きである．

ただし，どちらの条件も「画像と一般知識だけで面白さが分かるボケ」に絞るには十分でない．写真に写った有名人の知識を使うボケは，画像外の知識のラベルでは「いいえ」になるため，残る．また，画像外の知識の判定（F1 約 0.69）の誤りによる混入も残る．条件 A の写真のボケで画像外の知識の割合が約 31% とやや高いことは，写真のボケが実在の事物の知識に頼りやすいことを示唆する．ただし，原因は確かめていない．

精度の推定は，実データの 380 枚（写真のみの正例 149 枚）に基づく．そのため，95% 区間の幅は ±3〜5 ポイントある．正解は全て Claude Code の目視であり，v4 の目視は小さな文字を見落とす傾向があった．

ファイル

- プログラム：`programs/ex029_photo_subset/`（`data.py`，`evaluate.py`）
- 出力：`outputs/ex029_photo_subset/`（`counts.csv`，`metrics.csv`，`confusion.csv`，`boke_counts.parquet`，`fig_metrics.png`，`evaluate.log`）
- 可視化：`visualize_result.ipynb` の ex029 の節

未解決の論点と次の候補

- 条件 A のボケのうち，画像と一般知識だけで面白さが分かる割合：画像外の知識の閾値ごとに数百件を目視し，有名人への依存による混入の規模を測る．
- 有名人が写っている写真の判定：画像側のラベル（有名人が写っているか）か，ボケ側のラベル（画像に写った人

物の知識に依存するか）の追加を検討する．

- 写真のみの判定で，イラストやスクリーンショットの貼り合わせの誤検出が数 % ある．条件 A では文字ありで多くが除かれるが，残りの規模は未確認である．
- 精度の推定は 380 枚に基づく．条件 A の内部での誤りの率を細かく知るには，条件 A の予測から数百枚を抽出して目視するのが効率的である．