report_051：最終版のアノテーションの構成と精度

1. 概要

BoketeDBv5 のアノテーションの最終版の構成をまとめる．対象はパッケージ `Bokete_Annotation_programs_v5.0` の v5.3.0 であり，ボケの段階は v5.2.0 で実行したものである．お題画像とボケ（大喜利）のそれぞれについて，分類の方法，指示（プロンプト）の本文，精度（適合率・再現率・F1）を記す．

精度は新しい推論をせずに，パッケージの出力と既存の目視のラベルから `programs/ex030_final_summary/collect.py` で求め直した．出力は `outputs/ex030_final_summary/` にある．お題文ありの精度は ex025 と ex028 の出力から読み込んだ．目視のラベルは全て Claude Code が付けたものである．

表 1：アノテーションの全体の構成．

対象	ラベル	判定の方法	学習に用いたラベル	主な精度（実データの推定 F1）
お題画像 682 万件（代表 661 万枚）	形式・属性（空欄，カルタ記号，文字）・媒体 7 種	2 つの生徒の確率の平均（埋め込みの MLP と，微調整した SigLIP2-B）	Qwen3-VL-8B の教師ラベル（約 4.5 万枚）	0.82〜1.00（絵画を除く）
お題画像	お題文あり	埋め込みと形式・属性の確率を入力とする MLP と，形式ごとの閾値	Qwen3-VL-32B の教師ラベル（約 4.5 万枚）	0.79（v6 の R1b）
写真のみ 337 万枚	キャプション	Qwen3-VL-30B-A3B の生成	—	概要として十分 87%
ボケ 9,250 万件	発話の型（6 区分・3 区分），画像外の知識	Qwen3-VL-4B + LoRA の分類器（お題画像とボケの文を入力）	Qwen3-VL-32B の教師ラベル 34,634 件と，目視 931 件	6 区分 0.71，3 区分 0.86，画像外の知識 0.69（最終評価用）
ボケ	制約の順守	カルタ：書き出しの音の規則．穴埋め・お題文：同じお題の他のボケとの類似度	—	AUC 0.81，カルタの正解率 0.97
ボケ	画像中の文字への依存	形式による規則	—	—

2. お題画像のアノテーション

2.1 処理の流れ

表 2：お題画像の処理の段階．

段階	処理
list	画像を列挙する．sha256 が同じ画像は代表の 1 枚だけを予測する（6,823,270 件 → 6,609,511 枚）

段階	処理
predict	2 つの生徒で形式・属性・媒体の確率を求め，平均する．埋め込みを保存する
odai_text	保存した埋め込みと predict の確率から，お題文ありの生徒の確率を求める
verify（既定では行わない）	形式をお題文と予測した画像に，Qwen3-VL-8B で確認の質問をする
finalize	確率からラベルを決める（2.4 節）
caption	媒体が写真のみの画像に，キャプションを付ける（2.5 節）

定義書は第 5 版である（`docs/label_definition.md`）．属性は複数選択，媒体は原則 1 つ（合成画像のみ複数）である．形式は属性から「カルタ記号あり→ カルタ，空欄あり → 穴埋め，お題文あり → お題文，それ以外 →通常」の順に導く．

2.2 教師ラベル（形式・属性・媒体）

教師は Qwen3-VL-8B-Instruct である．温度 0，JSON スキーマによる構造化出力，入力は最大 448×448 画素（200,704 画素）とした．無作為の 4 万枚と，少ない区分（ゲーム，絵画，カルタなど）の画像約 5 千枚に，6 つの質問（部品）を問い，次の規則で組み合わせた（教師 T_v11．`programs/ex008_label_v4/teacher_v4.py`）．

表 3：教師の部品と組み合わせの規則．

部品	用途	組み合わせの規則
F_v2（英語）	形式	text をお題文とする
O_v11_en（英語）	お題文の確認	形式がお題文で，確認の質問が偽なら通常にする
J_v6（日本語）	空欄あり，カルタ記号あり（とその文字），お題文・その他の文字	空欄・カルタ記号をそのまま用いる
X_v10_en（英語）	読める文字があるか	文字あり＝ J_v6 のお題文かその他の文字，または（X_v10_en かつカルタ記号なし）
M_v6（日本語）	媒体	CG を除く．媒体が空ならイラストにする
P_v8_en（英語）	美術作品の絵画か	絵画を置き換え，絵画が真ならイラストを偽にする

さらに，ボケの書き出しの音が札のかなと合わないカルタを，空欄があれば穴埋め，文字があればお題文，それ以外は通常にする（ボケの書き出しによる照合）．属性は形式と整合させる．

各部品の指示の本文を次に示す（`programs/ex005_rare_weighted_distill/prompts.py`）．

F_v2（形式と画風）：

```
This image is a prompt image ("odai") from the Japanese comedy site Bokete. Classify it on two
↪  axes.

Q1 "format":
```

- "karuta": a single hiragana character is written inside a circle or square (like a karuta card). Users write a line starting with that hiragana.
- "anaume": there are blank placeholders to fill in, such as empty white boxes, empty speech bubbles, ○○, □, or ？ replacing words.
- "text": the image consists almost entirely of written text (typically a topic or question on a plain or colored background) and has no main photo, anime or manga picture.
- "normal": an ordinary photo, anime, manga or illustration. Pictures that contain captions, subtitles, signs, titles or speech bubbles with words are still "normal".

Q2 "domain" (the visual style of the main picture):
- "photo": real-world photograph or live-action video frame (including TV, movies, photographed toys).
- "anime": screenshot of an animated TV series or film.
- "manga": panel(s) of a manga or comic (line drawing, screentone, speech bubbles).
- "illust": other illustrations, CG, game screens, paintings, or plain text graphics.

Answer with JSON only: {"format": "...", "domain": "..."}

J_v6（属性．同じ指示に形式と媒体の節もあるが，教師には属性だけを用いた）：

この画像は大喜利サイト「ボケて」のお題画像です．以下の項目を上から順に判定し，JSON のみを出力してください．

1．属性（当てはまるものを true）：
- has_karuta_mark：カルタ記号がある（円や四角の枠の中にひらがな 1 文字だけを書いた，文から独立した記号．中身が空の枠や文章の一部の文字は該当しない．迷ったら false）．karuta_char にそのひらがなを書く（なければ空文字）．
- has_blank：語の代わりに置かれた空欄がある（白や色付きの矩形，○○，□，＿＿，語の代わりの「？」，語の代わりの黒塗り，話者に付いた空の吹き出し．テロップや字幕の中の空欄も含む）．顔や個人情報の目隠し，文末の疑問符は空欄ではない．
- has_prompt_text：投稿者が画像に重畳した，回答者への問いや指示の文がある（問い，指示，題目の句，状況の設定，名前などの列挙）．空欄を含む文そのものは該当せず，空欄とは別に問いや指示の文がある場合のみ true．テレビのテロップや字幕，看板，台詞，題名など投稿者が重畳したのではない文字は該当しない．迷ったら false．
- has_other_text：お題文とカルタ記号以外の，ボケに関わりうる文字がある（テロップ，字幕，看板，台詞など．透かし，ロゴ，判読できない小さな文字は除く）．
- composite：合成画像（複数の画像の貼り合わせ，写真と絵の重ね合わせ）．

（以下，形式と媒体の節は M_v6 とほぼ同じ文のため省略）

M_v6（媒体）：

この画像は大喜利サイト「ボケて」のお題画像です．媒体（原則 1 つだけ true．合成画像で異なる媒体の領域が画像の約 2 割以上ずつある場合のみ複数）：
- photo：現実の写真（実写の映像，フィギュアや人形，着ぐるみ，像を撮影したものを含む）
- anime：アニメのスクリーンショット
- game：ゲーム画面のキャプチャ（ゲームの会話画面，戦闘画面，ドット絵のゲーム画面を含む）
- cg：ゲームやアニメの画面ではない 3DCG
- manga：漫画作品から切り抜いたコマ
- text_graphic：文字や記号が主体で，写真や絵がほとんどない画像（ウェブページやアプリの画面を含む）
- painting：古典的絵画（浮世絵などの版画を含み，写真に撮ったものも絵画とする）

- illustration：上記に含まれない絵（キャラクターの描き下ろし，模写，漫画風の一枚絵，カルタの札の絵，手描きの絵を含む）

生成 AI による画像は，同じ見た目の画像を人が作った場合の媒体とする．
JSON のみを出力してください．

X_v10_en（読める文字）：

```
This image is a prompt image ("odai") from the Japanese comedy site Bokete. Answer with JSON only.
- has_any_text: is there any readable text anywhere in the image (Japanese characters, Latin letters or numbers)? Count every kind of text: overlaid questions, captions, subtitles, speech balloons, sound effects drawn in manga, signs, posters, product labels, text on clothing or uniforms, logos, watermarks, copyright notices, URLs, and date stamps. Do NOT count text that is blurred or mosaicked so that it cannot be read, text too small to read, or a karuta mark alone (a single hiragana in a circle or square).
```

P_v8_en（絵画と 3DCG．絵画の回答のみを用いた）：

```
This image is a prompt image ("odai") from the Japanese comedy site Bokete. Answer two independent questions with JSON only.
- is_fine_art_painting: is the main picture a work of fine art painted by a painter, such as an oil or watercolor painting, a classical portrait, a religious painting, a Japanese painting or an ukiyo-e print (including a photo of such a work and an edited version of a famous painting)? Anime, manga, cartoons, illustrations for books or games, and digital character art are NOT.
- is_3dcg_or_ai: is the main picture rendered with 3D computer graphics software or generated by AI (e.g. a 3D rendered character or scene, a photorealistic AI image)? Screenshots of video games or anime, real photographs and hand drawings are NOT.
```

O_v11_en（お題文の確認．パッケージの verify 段階と同じ文）：

```
This image is a prompt image ("odai") from the Japanese comedy site Bokete. Answer with JSON only.
- is_poster_prompt: does the image contain text that the poster wrote as the theme for the respondents to answer? This includes a question ("〜とは？", "What is ...?"), an instruction or request ("〜してください", "〜しろ"), a topic phrase ("こんな〜は嫌だ", "〜ある ある", "〜な事", "〜した奴優勝", "〜の共通点", "〜にありがちなこと"), a situation setting or short scenario, a title-like theme written on a plain background or a Bokete template, and a list of names or items to be used. Answer false only if all the text clearly comes from the original source material: signboards, posters, book or DVD covers, product packages, TV or news screens and captions, web articles, song lyrics, charts or diagrams, or dialogue in games, anime or manga.
```

2.3 生徒（形式・属性・媒体）

表 4：生徒の構成（docs/method.md）．2 つの確率を平均する．

モデル	構成	学習
埋め込みの MLP	`google/siglip2-so400m-patch14-384` の画像埋め込み（1,152 次元，L2 正規化）→ LayerNorm → 全結合（1,024）→ GELU → Dropout 0.3 → 形式・属性・媒体の出力層	AdamW，40 エポック，検証用で最良のエポック，3 seed の平均
微調整した SigLIP2-B	`google/siglip2-base-patch16-224` の画像エンコーダに 3 つの線形の出力層	224×224 画素，色の揺らぎの拡張，AdamW（学習率 3e-5），5 エポック

損失は，形式の交差エントロピーと，属性・媒体の 2 値交差エントロピーの和である．

2.4 お題文ありの判定と後処理

お題文ありは，第 5 版の定義（属性として空欄・カルタ記号と独立に付ける）に合わせて，別の生徒で予測する．

- 教師：Qwen3-VL-32B-Instruct（FP8，最大 802,816 画素）の指示 P3（ex024）．教師ラベルを付けたのは，2.2 節の約 4.5 万枚のうち文字ありの確率が 0.3 以上の 26,577 枚である．残りはお題文なしとした．
- 生徒：埋め込み（1,152 次元）に形式 4・属性 3 の確率を連結した 1,159 次元を入力とする MLP（構成は 2.3 節と同じ）．2 値交差エントロピー，AdamW（学習率 1e-3），40 エポック．3 seed の平均．
- 判定：形式の確率が最大のものがお題文なら，確率 0.05 以上でお題文あり．穴埋め・カルタなら 0.3 以上でお題文あり．通常ならお題文なし．
- 後処理（finalize）：属性・媒体は確率 0.5 以上を真とする（媒体が空なら最大の項目）．形式の確率が最大の項目から属性を補い，形式は属性から導く．

指示 P3（`programs/ex024_odaibun_attr/qwen_odaibun.py`．出力は`{"has_odai_text": bool}`）：

```
この画像は大喜利サイト「ボケて」のお題画像です．画像に「お題文」があるかを判定してください．

お題文とは，お題の投稿者が回答者に向けて書き加えた，大喜利の題となる文です．次のようなものです．
- 問い（「〜とは？」「〜なのはなぜ？」「最初に放った一言とは？」）
- 指示（「〜してください」「〜しろ」）
- 題目の句（「こんな〜は嫌だ」「〜あるある」「〜の共通点」「〜な事」）．題目の後に例が列挙され，最後の項目が空欄のものを含む
- 状況の設定（「〜したら…」「〜なのに」）や短い筋書き
- ボケてのテンプレートや無地の背景，画像の上下の帯に投稿者が書いた主題の文（台本，手紙の書き出し，題名など）

次のものはお題文ではありません．
- 空欄を含む文章のまとまり（段落，説明文，記事，字幕やテロップ，歌詞，引用，台詞）．空欄のない文が含まれていても，同じまとまりの一部ならお題文ではありません
- 空欄（□，○○，？，空の枠，空の吹き出しなど）を含む文そのもの．空欄とは別の文として問い・指示・題目・状況の文がある場合だけ，お題文ありとします
- 元の素材にある文字：テレビの字幕やテロップ，看板，ポスター，本・CD・DVD の表紙，商品，ウェブの記事，SNS や アプリの画面，ゲーム・アニメ・漫画の台詞，歌詞，人物やものの説明文
- 絵の中の吹き出しに書かれた登場人物の台詞
- ひらがな 1 文字のカルタの記号，ロゴ，透かし，署名
```

判断の手順：まず画像中の文字を，投稿者が書き加えたものと元の素材にあるものに分けます．次に，投稿者が書き加えた文字から，空欄を含む文章のまとまりを除きます．残った文字に問い・指示・題目・状況の文があればお題文ありです．迷う場合はお題文なしとします．
JSON のみを出力してください．

2.5 写真のキャプション

媒体が写真のみの画像（3,371,140 枚）に，Qwen3-VL-30B-A3B-Instruct-FP8 で日本語の 1 文を付ける．入力は最大 448×448 画素，温度 0，最大 64 トークン，vLLM の `VLLM_BATCH_INVARIANT=1`（再現性）とした．句読点を「、」「。」にそろえ，壊れた出力には `caption_ok` ＝偽を付ける．指示の本文は次のとおりである．

この写真の内容を，日本語で 30 字程度の 1 文で簡潔に説明してください．人物の名前は書かないでください．説明の文のみを出力してください．

2.6 精度

正解は，ex022 ／ ex023 で用いた 1,020 枚の目視のラベル（定義書 v4）である．実データは無作為抽出 160 枚と層別抽出 220 枚の重み付きの推定であり，括弧は群ごとの 2000 回の復元抽出による 95% 区間である．評価用データは少ない区分を多く含む 640 枚で，重みはない．形式のお題文は，正解が第 4 版の定義（投稿者が書いた問い）である．予測は第 5 版の定義（お題文あり）から導いたものであり，定義が完全には一致しない．

表 5：形式・属性・媒体の精度（v5.3.0）．

軸	項目	実：適合率	実：再現率	実：F1（95% 区間）	評価用：適合率	評価用：再現率	評価用：F1
形式	カルタ	1.00	1.00	1.00（1.00 – 1.00）	1.00	0.89	0.94
形式	穴埋め	0.93	0.97	0.95（0.90 – 0.98）	0.90	0.98	0.94
形式	お題文	0.85	0.83	0.84（0.72 – 0.94）	0.89	0.86	0.87
形式	通常	0.97	0.96	0.97（0.95 – 0.98）	0.98	0.96	0.97
属性	空欄あり	0.93	0.97	0.95（0.90 – 0.98）	0.91	0.98	0.94
属性	カルタ記号あり	1.00	1.00	1.00（1.00 – 1.00）	1.00	0.89	0.94
属性	文字あり	0.94	0.99	0.97（0.95 – 0.98）	0.94	0.99	0.97
媒体	写真	0.98	0.98	0.98（0.97 – 0.99）	0.98	0.98	0.98
媒体	アニメ	0.81	0.96	0.88（0.79 – 0.96）	0.82	1.00	0.90
媒体	ゲーム	0.97	0.83	0.90（0.72 – 1.00）	0.88	0.64	0.74
媒体	マンガ	0.97	1.00	0.99（0.96 – 1.00）	0.88	0.99	0.93
媒体	テキストグラフィック	0.97	0.87	0.92（0.87 – 0.96）	0.93	0.97	0.95
媒体	絵画	0.72	0.34	0.46（0.22 – 0.91）	0.80	0.80	0.80
媒体	イラスト	0.78	0.87	0.82（0.73 – 0.90）	0.85	0.75	0.80

実データの絵画は正例が少ない（380 枚中の重み付きの推定）ため不安定である．そこで，少ない区分の評価用データ 800 枚（ex005）での値を表 6 に示す．

表 6：少ない区分の評価用データ（800 枚．重みなし）．

項目	正例	適合率	再現率	F1
ゲーム	146	0.89	0.79	0.84
絵画	35	0.78	0.80	0.79
カルタ	125	0.99	0.93	0.96

項目	正例	適合率	再現率	F1

表 7：お題文ありの精度（全データの推定）.

定義	評価用データ	適合率	再現率	F1
第 5 版	ex025 の層別抽出 420 枚	0.74	0.95	0.83
第 6 版の R1b	ex028 の 600 枚＋層 D・F の追加 600 枚（report_049）	0.83	0.75	0.79（0.75 – 0.83）

第 6 版の正解では，字幕に重ねた問い（元の素材の字幕を含む）もお題文ありとする．v5.3.0 は第 5 版の定義で学習したため，これを見逃すことが再現率の低さの主因である（report_049）．後段の組み合わせ（v5.3.0 の確率＋ 32B の書き起こし）では F1 0.835 になるが，パッケージには入っていない（report_048）.

表 8：絞り込みの条件の精度（実データの推定．report_050）.

条件	適合率	再現率	F1	お題	ボケ
写真のみ	0.95	0.99	0.97	347 万件	3,821 万件
写真・文字なし（v6 の文字の正解）	0.96	0.98	0.97	201 万件	2,129 万件
写真・通常（v4 の正解）	0.98	0.99	0.98	306 万件	2,991 万件

キャプションは，写真の無作為の 240 枚で，参照のキャプションと Qwen3-VL-32B による 5 段階の採点で評価した．平均点は 4.13，概要として十分（4 点以上）は 87%，画像にない内容や誤りを含むものは 13% であった．採点者と目視の採点の一致は，「4 点以上」かどうかで 87%（160 件）であった.

実データで全項目（形式・属性・媒体）が目視と一致する画像の割合は 0.838 と推定されている（v5.2.0. `docs/method.md`）.

3. 大喜利（ボケ）のアノテーション

3.1 発話の型と画像外の知識

定義書は第 3 版である（`docs/boke_label_definition.md`）．発話の型の 6 区分は，セリフ（S），心の声（M），ツッコミ・呼びかけ（T），状況の説明・物語（N），名付け・見立て（L），回答（A）である．3 区分は，登場人物の言葉（S，M），外からの言葉（T，N，L），回答（A）とする．画像外の知識は，「画像にも画像中の文字にも示されていない特定の事物の知識が，面白さの理解に必要か」の 2 値である.

判定は，お題画像とボケの文を入力とする分類器で行う.

- モデル：Qwen3-VL-4B-Instruct の全ての線形層にランク 16 の LoRA を付ける．言語モデルの最終層の，入力の最後のトークンの隠れ状態に，発話の型（6 区分）と画像外の知識（2 値）の出力層を付ける．生成はせず，1 回の順伝播で判定する.
- 学習：二段階で行った．第 1 段階では，Qwen3-VL-32B（FP8）の教師ラベル 34,634 件で学習した．第 2 段階では，目視のラベル 931 件で微調整した．教師のラベルだけでは，教師の偏り（セリフをツッコミとするなど）を受け継ぎ，6 区分が 0.55 にとどまった.
- 判定：発話の型は確率が最大の区分とする．画像外の知識は確率 0.5 以上を「はい」とする．回答も分類器が判定する（教師ラベルでは，形式が穴埋め・お題文のボケを規則で回答とした）.
- 推論：LoRA を重みに統合する．同じお題のボケでは，お題画像とお題の部分の計算を 1 回にまとめて共有する（プレフィックスのキャッシュ）．速さは約 345 件/秒で，全件は約 3.1 日である.

分類器への入力の文（bokete_annotation/boke.py．お題画像は長辺 448 画素以下）：

```
大喜利サイト「ボケて」のお題画像（形式：{形式}）に投稿されたボケ：「{ボケの文．改行を空白にし，200 文字まで}」
```

教師の指示 one_kt_cap（Qwen3-VL-32B．programs/ex015_boke_labels_v3/teacher.py）は次のとおりである．お題の形式・媒体・画像中の文字の有無と，写真のキャプションを文で加える．

```
これは大喜利サイト「ボケて」のお題画像と，それに投稿されたボケです．
お題の形式：通常（画像に自由に一言を付ける）
お題画像の媒体：{媒体}．画像中の文字：{あり／なし}
お題画像の説明：{写真のキャプション}
ボケ：「{ボケの文}」

1．voice：ボケが誰の視点の，どのような言葉か．次の手順で 1 つ選ぶ．
   （1）ボケが名詞句（体言止め）で，画像全体や写っている物に名前・題・例えを付けている（「〜の時の俺」「〜界の〜」を含む）→ L
   （2）話し手が画像の中の人物・動物・物（擬人化を含む）で，声に出している（呼びかけ，返事，叫び，掛け合い）→ S
        心の中の考え，独り言 → M（迷う場合は S）
   （3）話し手が画像の外の人で，画像の出来事や前後の状況を説明する文 → N
        画像を見て言う感想・指摘・ツッコミ，画像の人物への呼びかけ → T

2．画像外の知識を，次の手順で答える．
   referent：ボケの面白さが依存している事物の名前．なければ空文字．
   referent_type：referent の種類を次から 1 つ選ぶ．固有名詞でなければ general とする．
     work：特定の作品・キャラクター・番組・映画・ゲーム・歌・CM・有名な台詞やキャッチコピー
     person：実在の特定の人物・団体
     product：特定の商品・ブランド・店
     place：特定の地名と，その土地の印象
     event：特定の出来事・ニュース・流行語・ネットの定型
     bokete：ボケての機能や慣習
     general：普通名詞（一般の物，道具，料理，スポーツ，法律，職業，ジャンル，生活の行事，遊び），ことわざ，慣用句
     none：依存する事物がない
   in_image：referent が画像に写っている，画像中の文字で名指しされている，または画像に写っているキャラクターと同じ作品の登場人物・設定か．
   necessary：referent を知らない人には，一般の日本語の語彙と常識があってもボケの面白さが分からないか（名前が背景にすぎないなら false）．

JSON のみを出力してください．
```

出力は JSON スキーマで voice（S，M，T，N，L），referent，referent_type，in_image，necessary に制約した．画像外の知識は，referent_type が固有の種類（work，person，product，place，event，bokete）で，in_image が偽で，necessary が真のときに「はい」とする．

3.2 制約の順守と画像中の文字への依存

- カルタ：ボケの書き出しの音（漢字・カタカナは読みに変換）が，札のかな（そのお題のボケの書き出しの最頻値）と一致するかを判定する．漢字で始まるボケは順守とみなす．
- 穴埋め・お題文：同じお題の他のボケ（最大 50 件）のうち，ruri-v3-310m の文の埋め込みが最も似た 5 件とのコサイン類似度の平均を得点（`compliance_score`）とする．しきい値は設けていない．
- 画像中の文字への依存（`uses_image_text`）：形式が穴埋め・お題文なら真とする規則である．

3.3 精度

正解は，検証データ 620 件（調整用 308 件，最終評価用 312 件）の合意ラベルである．合意ラベルは，元のラベルと，元のラベルを見ずに付け直したラベルの不一致を裁定したものである．予測は，パッケージのコードで検証データを推論した結果（ex019 の `verify_eval_pred.csv`）である．

表 9：発話の型と画像外の知識の精度（正例・適合率・再現率・F1 は最終評価用 312 件の値）．

ラベル	区分	正例	適合率	再現率	F1	調整用の F1
6 区分	セリフ（S）	110	0.79	0.87	0.83	0.88
6 区分	心の声（M）	31	0.82	0.45	0.58	0.52
6 区分	ツッコミ・呼びかけ（T）	14	0.41	0.50	0.45	0.56
6 区分	状況の説明・物語（N）	42	0.68	0.86	0.76	0.88
6 区分	名付け・見立て（L）	43	0.73	0.74	0.74	0.80
6 区分	回答（A）	72	1.00	0.83	0.91	0.92
6 区分	マクロ平均	312	0.74	0.71	0.71	0.76
3 区分	登場人物の言葉	141	0.88	0.86	0.87	0.90
3 区分	外からの言葉	99	0.76	0.88	0.82	0.87
3 区分	回答	72	1.00	0.83	0.91	0.92
3 区分	マクロ平均	312	0.88	0.86	0.86	0.89
画像外の知識	はい	84	0.67	0.71	0.69	0.67

回答の再現率が 0.83 にとどまる理由は，入力の形式にある．正解が回答の 143 件（全体）のうち，入力の形式が穴埋め・お題文の 120 件は全て回答と判定された．一方，入力の形式が通常の 23 件は全て回答以外と判定された．この誤りは，お題画像の形式の判定に依存する．

表 10：その他の精度と，目視のラベルの再現性．

評価	値
穴埋め・お題文の順守の得点：正しい組と，別のお題に付け替えた組との判別（AUC）	0.81（穴埋め 0.74，お題文 0.88）
カルタの順守の規則：検証データのカルタのボケ 102 件の正解率	0.97
目視のラベルの再現性（同じ判断者が付け直したときの一致．F1）	6 区分 0.80，3 区分 0.93，画像外の知識 0.85
画像外の知識の割合（全件の予測）	27.1%（検証データの目視は 22〜25%）

穴埋め・お題文の順守は，違反の実例がまれである（検証データで 1 件）．そのため，付け替えた組を違反の代わりにして評価した．

4. 考察

お題画像の形式・属性・媒体は，写真・文字あり・マンガ・通常・カルタで F1 0.97 以上であり，実用上十分である．精度が低いのは，次の 3 つである．

- 絵画（少ない区分の評価用データで F1 0.79）
- イラストとアニメ・ゲームの境界（F1 0.74〜0.90）
- お題文あり（第 6 版の正解で F1 0.79）

お題文ありの再現率の低さは，第 6 版で定義を広げた（元の素材の字幕の問いを含めた）ことによる．第 5 版の定義では F1 0.83 である．

ボケの発話の型は，3 区分で F1 0.86，6 区分で 0.71 である．6 区分のうち心の声とツッコミは，人の判断の揺れも大きい．画像外の知識は F1 0.69 で，目視の再現性（0.85）との差が最も大きい．主な誤りは，有名な台詞・歌詞・ネットの定型の引用の見逃しと，画像に写っている作品の登場人物の名前を画像外とする誤検出である．

全ての正解は Claude Code の目視であり，人による評価は行っていない．目視の判断者内の再現性は，お題文ありで 97%（report_048），ボケの 3 区分で F1 0.93 である．

5. ファイル

- パッケージ：`Bokete_Annotation_programs_v5.0/`（`docs/method.md`，`docs/label_definition.md`，`docs/boke_label_definition.md`）
- 指示：
  - 画像の教師の部品：`programs/ex005_rare_weighted_distill/prompts.py`
  - 組み合わせの規則：`programs/ex008_label_v4/teacher_v4.py`
  - お題文あり P3：`programs/ex024_odaibun_attr/qwen_odaibun.py`
  - ボケの教師 one_kt_cap：`programs/ex015_boke_labels_v3/teacher.py`
  - 確認の質問・キャプション・ボケの分類器の入力：`bokete_annotation/verify.py`，`config.json`，`bokete_annotation/boke.py`（パッケージ内）
- 精度の集計：`programs/ex030_final_summary/collect.py`，出力 `outputs/ex030_final_summary/`（`image_metrics.csv`，`rare_metrics.csv`，`odai_text_metrics.csv`，`boke_metrics.csv`，`collect.log`）

6. 未解決の論点

- お題文ありを第 6 版の定義で学習し直すか（v5.3.0 は第 5 版の定義で学習）．面白さの判定を写真・文字なしに限るなら，影響は小さい．
- 画像外の知識は F1 0.69 である．写真に写った有名人の知識は「画像外」に含めない定義であり，面白さの判定で一般知識の範囲に絞るには不十分な可能性がある．
- 全ての正解は同じ判断者（Claude Code）の目視であり，人との一致は未確認である．