report_052：最終版のアノテーションの独立したディレクトリへの書き出し

概要

最終版のアノテーションを,新しいプロジェクトで単独で使えるディレクトリ/mnt/d/BoketeDBv5_annotation_final/に書き出した．対象はパッケージ v5.3.0（ボケは v5.2.0）である．書き出したものは，データ，ラベルの基準（定義書），判定の方法と指示（プロンプト），精度の表，評価に用いた目視のラベル，アノテーションのパッケージである．このディレクトリは研究のリポジトリの外にあり，ここだけを複写すれば使える．書き出しは programs/ex031_export_final/export.py で行い，同じコマンドで再開・再実行できる．

方法

export.py は次の 4 つを行う．

- 複写：パッケージの出力（Bokete_Annotation_programs_v5.0/outputs/BoketeDBv5_annotation/）から，お題画像のラベル，画像の一覧，キャプション，確率，埋め込み，お題文ありの確率，ボケのラベル，集計の json を複写する．定義書，方法の文書，最終版のまとめ（report_051），部分集合の精度（report_050）と，パッケージのコードとモデルの重みも複写する（outputs，.git，キャッシュを除く）．大きさと更新時刻が同じファイルは飛ばす．
- 部分集合の一覧：写真のみ，写真・文字なし，写真・通常のお題の一覧を書き出す（ex029 と同じ条件）．列は odaiId，rep_odaiId，ボケの件数 n_boke，画像外の知識が要るボケの件数 n_outside である．
- 目視のラベル：各実験のデータの読み込みの関数で読み直し，CSV にする．対象は，お題画像 1,020 枚（第 4 版），文の属性（第 6 版の草案）1,620 枚・636 枚・600 枚，ボケの検証データ 620 件（合意ラベル）である．キャプションの参照文 240 枚は，元のファイルを複写する．
- 指示の本文：教師と分類器の指示を，各実験のコードの定数から書き出す．画像の教師の 6 つの部品，お題文ありの P3，キャプション，ボケの教師 one_kt_cap（差し込む値は {} で示す），ボケの分類器の入力の文の 10 ファイルである．

書き出し先の README.md は programs/ex031_export_final/README_final.md を複写したものである．構成，列の説明，使い方の例，判定の方法，精度の要約，評価用ラベルの説明，注意を記した．

結果

表 1：書き出したもの．

場所	内容	件数・大きさ
data/odai/	annotation.parquet（6,823,270 行），images.parquet，captions.parquet，predict/，embeddings/（SigLIP2，1,152 次元），odai_text/，summary.json	約 16GB（埋め込み約 15GB）
data/boke/	boke_annotation/（814 ファイル，約 9,250 万件），boke_summary.json	約 2.7GB
data/subsets/	photo_only（3,474,756 お題），photo_notext（2,009,955），photo_normal（3,063,330）	—

場所	内容	件数・大きさ
docs/	定義書（第 4 版，第 5 版，第 6 版の草案，ボケ第 3 版），method.md，data_format.md，final_summary（report_051），photo_subset（report_050），prompts/（10 ファイル）	—
eval/	目視のラベル 5 ファイル（1,020，1,620，636，600，620 行），キャプションの参照文 2 ファイル（各 120 枚），metrics/（精度の表 7 ファイル）	—
annotator/	パッケージのコード，設定，文書，テスト，モデルの重み	約 537MB

複写の結果は outputs/ex031_export_final.log と書き出し先の export_log.json に記録した．埋め込み（34 ファイル）とボケのラベル（814 ファイル）は，複写元と大きさが全て一致した．書き出し先で README.md の使い方の例を実行し，読み込めることを確かめた（写真・文字なしのお題で，画像外の知識が要らないと判定されたボケは 14,741,721 件）．全体の大きさは約 19GB である．

使い方

新しいプロジェクトでは，/mnt/d/BoketeDBv5_annotation_final/ を複写し，README.md と docs/final_summary.md を最初に読む．面白さの判定に用いる写真・文字なしのお題は，data/subsets/photo_notext.parquet の odaiId で，ボケのラベル（data/boke/boke_annotation/）と結合して得られる．

ファイル

- プログラム：programs/ex031_export_final/export.py，README_final.md
- 書き出し先：/mnt/d/BoketeDBv5_annotation_final/（リポジトリの外）
- 記録：outputs/ex031_export_final.log，/mnt/d/BoketeDBv5_annotation_final/export_log.json

未解決の論点と次の候補

- 書き出し先は Git で管理していない．別の場所に保存する場合は，ディレクトリごと複写する（約 19GB）．
- 元のお題画像のファイルと BoketeDBv4 の表（ボケの文など）は含めていない．ボケの文は BoketeDBv4 の boke の表から id で結合する．
- 次の作業は，写真・文字なしのボケでの面白さの判定の課題の設計である（評価の分布，同じお題の中の相対的な面白さ，お題単位の分割）．